

AI 과학자 시스템의 형식화: 구성요소 프레임워크와 이론적 분석

신재솔 (Jaesol Shin)
WeDataLab
ysys143@gmail.com
<https://github.com/ysys143>

Abstract

AI 과학자 시스템—가설을 생성하고, 실험을 실행하며, 지식을 합성하는 에이전트—의 분야는 교차 시스템 비교를 위한 공유된 형식 어휘가 부재하다. 본 논문은 S, G, E, V, M, π , 즉 탐색 공간(Search space), 가설 생성기(hypothesis Generator), 실험 실행기(Experiment executor), 검증기(Validator), 메모리(Memory), 탐색 정책(search Policy, π)의 여섯 구성요소 분류 체계를 부분 관측 마르코프 결정 과정(POMDP) 및 베이지 실험 설계(BED) 이론에 기반하여 제안한다. 이 프레임워크의 핵심 기여는 현재 시스템들이 뭉뚱그리는 세 가지 진단적 분리다: 관측 가능도와 보상 채널로서의 검증기의 분리; 보정된 게이팅(V_{gating})과 단순 계층 존재($V_{present}$)의 분리; 일화 메모리와 의미 메모리의 분리. 본 논문은 이 분리들을 다루기 쉽고 식별 가능한 가정 하의 세 명제로 형식화한다—발견 루프는 검증기와 무관하게 닫히고; 잘못 결합된 검증기는 수렴을 잘못된 표적으로 유도하며; 모든 자동 채널에 부재한 신규성 성분은 비식별 가능하다(명제 1-3)—단, 조사된 어떤 시스템도 해당 가정을 충족하지 않으므로 이 명제들은 서베이에 직접 적용되는 것이 아니라 구분들의 형식 구조를 명료화한다. 이 어휘를 여섯 개 핵심 AI 과학자 시스템과 일곱 개 과학 도메인에 적용하고, 반증 기준이 있는 세 가지 미해결 문제를 식별한다: 검증된 자동 신규성 게이트의 부재, 탐색 정책의 BED-실제 격차, 실험 충실도 격차—계산 proxy 실험과 물리 실험 사이의 승격 기준 부재. 교차 시스템 서베이는 잠정적 구조화 주석으로 제시된다: 게이팅 보정이 신뢰 가능한 폐쇄와 공존한다는 조직화 가설은 일부 결과 재코딩 가정 하에서 방향 일관성이 있으나 모든 합리적인 가정 하에서 결론이 나지 않으며, 경험적 발견이 아니라 잠정적 구조화 주석으로 읽어야 한다.

1 서론

AI 과학자 시스템—가설을 독립적으로 생성하고, 실험을 실행하며, 지식을 합성하는 에이전트—은 급속도로 증가하고 있으나 [Boiko et al., 2023, Lu et al., 2024, 2026, Schmidgall et al., 2025, Feng et al., 2026, Liu et al., 2026], 이 분야는 공통된 형식 어휘가 부재하다. 각 시스템은 고유한 용어를 도입하여 체계적인 비교를 어렵게 한다. 실제 배포에 직결되는 세 가지 질문이 여전히 미답 상태이다: 어떤 요소가 시스템의 페루프 운영 가능 여부를 결정하는가? 자율적 신규성 평가는 왜 지속적으로 실패하는가? 이론적으로 최적인 탐색 정책은 무엇인가?

본 논문은 세 가지 기여로 이 격차를 해소한다: (1) Servo¹, AI 과학자 시스템을 POMDP 및

¹프레임워크 이름은 서보메커니즘에서 따왔다: 서보 루프가 피드백(오차) 신호에 따라 표적으로 수렴하듯, AI 과학자는 검증기 V 가 신뢰 가능한 피드백 신호를 공급할 때에만 발견 루프를 닫는다—이것이 본 프레임워크의 핵심 관심사다.

베이지스 실험 설계 이론과 연결하는 형식 프레임워크 (S, G, E, V, M, π) (§4); (2) 여섯 개의 핵심 시스템, 아티팩트 인프라 제안, 그리고 일곱 개 과학 분야에 걸친 도메인별 구체화 분석 (§5, §6); (3) 모든 현재 시스템에 걸쳐 진전을 제약하는 세 가지 미해결 문제 (§7). 따라서 본 논문의 기여는 강한 경험 법칙이라기보다 진단적 어휘다: Servo는 기계적 폐쇄, 검증기 보정, 신규성 판단, 의미 메모리를 하나의 자율성 개념으로 뭉뚱그리지 않고 분리해 다룬다.

범위. 본 논문은 가설-실험-검증 주기를 통해 과학적 발견을 자동화하는 것이 주된 목표인 시스템을 다루며, 인간 주도 파이프라인 내 특화 도구 [Jumper et al., 2021]는 제외한다.

2 배경

Kaelbling et al. [1998]의 POMDP 정식화에 따라, AI 과학자 시스템을 부분 관측 마르코프 결정 과정으로 모델링한다: 진상태 s (자연의 미지 구조)는 직접 접근 불가능하며; 시스템은 실험적 관측으로 업데이트되는 믿음 상태 $b(s)$ 를 유지한다. 형식적으로, AI 과학자 POMDP는 튜플 $(S, \mathcal{A}, T, R, \Omega, \mathcal{O}, b_0, \gamma)$ 이며, 여기서 $\mathcal{A}$ 는 행동 공간(가설 생성 및 실험 실행), T 는 전이 함수, R 은 보상(발견의 과학적 가치), $\mathcal{O}$ 는 잡음이 있는 관측 과정, b_0 는 초기 믿음, γ 는 할인 인자이다. 믿음은 베이지스 규칙 $b'(s') \propto \mathcal{O}(o | s', a) \sum_s T(s' | s, a) b(s)$ 로 갱신되며, π 는 접근 불가능한 상태 s 가 아니라 믿음 b 에 따라 행동한다. 세 가지 속성이 표준 제어 문제와 구별한다: R 은 사전에 명시될 수 없다(유의성은 선형적으로 정의되지 않음); S 는 무한하다; T 는 비정상적이다(축적된 지식이 탐색 전선을 변화시킴). 따라서 우리는 POMDP를 개방형 과학의 완전히 명시된 모델이 아니라 조직화 형식으로 사용한다: §4.1의 형식 결과는 이 일탈들이 제한되는 다루기 쉬운 하위문제(가정 1)에서 성립하며, 일반적 개방형 경우는 미해결로 남긴다. 조사된 어떤 시스템도 가정 1을 완전히 충족하지 않는다—모든 시스템이 S 가 무한하거나, T 가 비정상적이거나, R 이 사전에 명세될 수 없는 체제에서 운영된다—따라서 명제들은 여기서 분석된 어떤 시스템에도 직접 적용되지 않으며, 이상화된 하위문제에 적용된다. 전반에 걸쳐 “루프 폐쇄”의 세 가지 구별된 의미를 분리해야 한다: (i) 다루기 쉬운 하위문제에서의 θ^* 에 대한 사후 집중(명제 1-3); (ii) V 의 피드백이 G 로 흘러 들어가는 계산적 폐쇄; (iii) 수용 게이트가 신뢰 가능하게 진리를 추적하는 신뢰 가능한 폐쇄. 명제들은 (i)을 수립하고; 서베이는 (iii)에 관한 것이며; 시스템들은 (i)이나 (iii) 없이 (ii)를 달성할 수 있다. 베이지스 실험 설계(BED) [Chaloner and Verdinelli, 1995, Rainforth et al., 2024]는 탐색 정책 π 의 정보 목적에 대한 하나의 규범적 기준을 제공한다: 기대 정보 이득(EIG)을 최대화하는 d^* 를 선택하고,

$$d^* = \arg \max_{d \in \mathcal{D}} \text{EIG}(d) = \arg \max_d \mathbb{E}[H(\theta) - H(\theta | y, d)] \quad (1)$$

여기서 $H(\theta)$ 는 매개변수 θ 에 대한 사전 엔트로피이고, $H(\theta | y, d)$ 는 d 하에서 y 를 관측한 후의 기대 사후 엔트로피이다. EIG는 변분 방법 [Foster et al., 2019], 분할 상환 정책 [Foster et al., 2021], 강화학습 [Blau et al., 2022]으로 근사할 수 있으나, 현재 어떤 AI 과학자 시스템도 이를 구현하지 않는다—§7에서 다루는 격차이다.

3 관련 연구

AI 과학자 시스템. 선행 연구 [Lu et al., 2024, 2026, Schmidgall et al., 2025, Boiko et al., 2023]는 개별 시스템에 대한 정성적 특성화를 제공하지만 교차 시스템 비교를 위한 공통 프레임워크는 없다; 아이디어 생성 연구 [Si et al., 2024, Baek et al., 2024]는 완전한 발견 루프를 통합하지 않은 채 품질 기준선을 수립한다. 지식 그래프 기반 아이디어 생성 시스템 [Gu

and Krenn, 2024, Lee et al., 2025]은 의미 메모리를 관계형 코퍼스로 구조화하면 가설 생성 품질이 향상될 수 있음을 보여주지만, 마찬가지로 루프를 닫지 않는다.

자율 과학 프레임워크. 페루프 자율 발견은 LLM 시대에 선행한다: Robot Scientist [Sparkes et al., 2010]은 효모 기능유전체학에서 가설 생성, 로봇 실험, 통계적 검증을 통합하여 LLM 기반 시스템보다 10년 이상 앞서 Servo의 여섯 구성요소 전체—능동학습 정책 포함—를 물리적 습식 실험실 형태로 구체화했다. 보다 최근의 통합 프레임워크로는 아이디어 생성에서 검증까지 12개 과학 과제에 걸친 페루프 다중 에이전트 시스템 NovelSeek [Zhang et al., 2025]와 생물의학 wet-lab 검증을 갖춘 다중 에이전트 가설 생성 시스템 Co-Scientist [Gottweis et al., 2026]가 있다. 따라서 우리는 Servo를 자동 발견을 위한 최초의 통합 프레임워크가 아니라, 검증기 완결성·계산-물리 실험 경계·POMDP/BED 관계를 최근 LLM 에이전트 하위 분야 안에서 명시화하는 형식적 어휘로 위치시킨다. 기존 프레임워크 대비 Servo의 증분적 진단 가치는 두 지점에서 가장 두드러진다. 첫째, 표준 POMDP 분류와 NovelSeek의 다중 에이전트 프레임워크는 루프 폐쇄/개방을 구분하지만 V_{present} (보정된 계층이 존재함)와 V_{gating} (결정적 수용 게이트가 보정되었음)을 분리하지 않는다. 둘째, 기존 POMDP 처리는 루프 폐쇄를 이진으로 뭉뚱그리는 반면, Servo의 세 방향 분리(사후 집중, 계산적 폐쇄, 신뢰 가능한 폐쇄)는 이를 진단적으로 구분한다.

이론적 기반. POMDP 프레임워크 [Kaelbling et al., 1998]와 BED [Chaloner and Verdinelli, 1995, Rainforth et al., 2024]는 고전적이다. 베イズ 최적 실험 선택은 자동 과학에서 오랜 역사를 가지며—가장 직접적으로는 Robot Scientist의 능동학습 정책 [Sparkes et al., 2010]에서—본 논문은 이 전통 위에서 POMDP(구조적 정식화)와 BED(규범적 정책 기준)를 현대 LLM 에이전트 환경에 대해 연결하며, 이 아이디어 자체의 선취권을 주장하지는 않는다.

과학의 형식 모델과 아티팩트 인프라. Taniguchi et al. [2025]는 집합적 예측 코딩을 과학의 사회적 모델로 제안한다; 본 논문은 상호 보완적인 단일 시스템 모듈형 분해를 제공한다. Liu et al. [2026]은 §5.1 및 §7에서 논의되는 V 및 M_s 기여로서 아티팩트 검증을 다룬다.

4 Servo 프레임워크

AI 과학자 시스템을 다음 구성요소를 가진 튜플 (S, G, E, V, M, π) 로 정의한다:

$$\text{Servo} = (S, G, E, V, M, \pi) \quad (2)$$

S : 탐색 공간 (Search Space) 탐색 대상인 후보 가설, 프로그램, 분자, 실험 조건 또는 기타 객체의 집합. S 는 정적이거나 동적으로 확장(개방형)될 수 있다.

$G: M \times S \rightarrow h$: 가설 생성기 (Hypothesis Generator) 축적된 메모리 M 과 탐색 공간의 현재 상태를 조건으로 새로운 후보 $h \in S$ 를 제안하는 함수. G 는 LLM 생성, 진화적 돌연변이, 또는 기호적 탐색을 수반할 수 있다.

$E: h \times P \rightarrow o$: 실험 실행기 (Experiment Executor) 프로토콜 P 하에서 가설 h 를 실행하여 관측 o 를 생성하는 함수. E 의 충실도는 빠른 계산 시뮬레이션(낮은 비용, 잠재적 대리 오차)에서 물리적 습식 실험실 실행(높은 비용, 실제 정답)까지 다양하다.

$V : o \rightarrow r$: 검증기 (Validator) 관측 o 에 보상 신호 r 을 할당하는 함수. V 의 네 계층을 구별한다:

$$\begin{aligned} V_{\text{syntax}} : o &\rightarrow \{\text{pass}, \text{fail}\} && (\text{결정론적, 고속}) \\ V_{\text{semantic}} : o &\rightarrow r \in [0, 1] && (\text{LLM 기반, 확률적}) \\ V_{\text{empirical}} : o &\rightarrow r && (\text{재현 기반}) \\ V_{\text{human}} : o &\rightarrow \{\text{novel}, \text{significant}\} && (\text{인간 위임}) \end{aligned}$$

M : 메모리 (Memory) (M_e, M_s, M_p)로 구성. M_e (일화)는 개별 기록 (h_i, o_i, r_i)를 저장; M_s (의미)는 증류된 지식 패턴을 저장; M_p (절차)는 학습된 프로토콜을 저장. M 의 구조는 G 와 π 의 품질을 직접 결정한다.

$\pi : b(S) \times M \rightarrow h$: 탐색 정책 (Search Policy) 다음 가설을 선택하는 결정 규칙. 믿음 상태 $b(S)$ 는 각 실험 후 업데이트된다. BED 해석에서 $\pi^* = \arg \max_d \text{EIG}(d)$ (식 1). 실제로는 반응형(ReAct)에서 탐욕적, 트리 탐색까지 다양한 정책이 사용된다.

운영 루프는 다음과 같다:

$$\begin{aligned} \pi(b, M) &\rightarrow G(M_s, S) \rightarrow E(h, P) \rightarrow V(o) \\ &\rightarrow M += (h, o, r) \rightarrow b(S) \text{ 업데이트} \rightarrow \text{반복} \end{aligned} \quad (3)$$

인간 개입 정도를 나타내는 보조 매개변수 $H \in [0, 1]$ 을 추가로 도입한다: $H = 0$ 은 완전 자율 시스템, $H = 1$ 은 인간이 G 또는 π 의 역할을 맡는 시스템이다.

4.1 검증기 완결성: 형식적 분석

V 를 쉽게 혼동되는 두 대상으로 분리하여 그 역할을 정밀화한다: 베이지 믿음 갱신을 구동하는 관측 가능도 $p(o \mid \theta, d)$ 와, 정책 π 가 결과를 점수화하는 데 쓰는 보상 추정치 검증기 $V(o)$. 아래 결과는 다루기 쉬운 하위문제에서 성립하며, 개방형 영역은 미해결로 남긴다. 중요한 것은 보정된 계층이 존재하느냐가 아니라 수용을 게이트하는 계층이 보정되었느냐다: 편향된 의미/사회 계층이 수용을 결정하면 보정된 경험적 검사도 무력화될 수 있다 (§8 및 보충 자료).

가정 1 (다루기 쉽고 식별 가능한 하위문제). (i) 탐색 공간 S 가 유계이고 매개변수 공간 Θ 가 콤팩트하다; (ii) T 가 정상적이다; (iii) 사전 분포 $p(\theta)$ 의 받침이 참값 θ^* 를 포함한다; (iv) 관측 모델 $p(o \mid \theta, d)$ 가 올바르게 명세되어 있고 θ 를 식별한다($\theta \neq \theta'$ 이면 둘을 분리하는 도달 가능한 설계가 존재); (v) 실현된 설계 수열이 사후 일치성을 위해 충분히 정보적이다—무한히 자주, 생존 가설 쌍 간 쿨백-라이블러 분리가 고정된 $\delta > 0$ 이상인 도달 가능한 설계를 선택한다. KL-분리 조건과 EIG 합 발산은 동치가 아니다: 증분 EIG는 유한 상태 설정에서 초기 엔트로피에 의해 유계되는 기대 엔트로피 감소이므로 사후 분포가 집중하더라도 누적 EIG는 유계될 수 있다. 여기서 조건은 가설 간 KL-분리에 관한 것이며, 누적 EIG에 관한 것이 아니다.

정의 1 (보상 채널로서의 검증기). $V(o)$ 는 참 보상 $R(s, a)$ 를 추정한다; $\mathbb{E}[V(o) \mid s, a] = R(s, a)$ 이면 보정됨, 어떤 (s, a) 에서 $\delta(s, a) = \mathbb{E}[V(o) \mid s, a] - R(s, a) \neq 0$ 이면 편향됨이라 한다. V 는 명시적으로 결합되지 않는 한 갱신 가능도 $p(o \mid \theta, d)$ 와 구별된다.

명제 1 (폐쇄를 위한 충분성). 가정 1 하에서 사후 분포는 θ^* 에 집중하고(루프가 닫힌다), 일단계 EIG 규칙(식 1)은 정보 목적함수에 대해 근시안적으로 최적이다—둘 다 검증기와 무관하다. V 는 보상 채널인 반면 EIG는 사전 분포와 가능도만의 범함수이기 때문이다.

증명 개요. 콤팩트 Θ 위에서 올바르게 명세된 식별 가능 가능도와 발산하는 누적 정보(가정 1(i),(iv),(v))는 베이즈 사후 일치성의 표준 충분조건이며 [Ghosal and van der Vaart, 2017], $b_t \rightarrow \delta_{\theta^*}$ 를 준다. 보정은 일치성에도 EIG 최적성에도 필요하지 않으며(둘 다 사전 분포와 가능도에만 의존), 별개의 보상 채널에 관여한다(아래에서 정밀화). 균일 정보 조항 (v)가 본질적이다: $\text{EIG}(d_t) > 0$ 이지만 $\sum_t \text{EIG}(d_t) < \infty$ 인 수열은 식별성과 보정 하에서도 사후 분포를 점질량에 이르지 못하게 한다. $\square$

명제 2 (오설정 결합 하의 표류). 검증기가 믿음 갱신에 들어간다고 하자, 즉 유효 갱신이 결합 $\beta > 0$ 로 $q_\theta(o) \propto p(o | \theta, d) \exp(\beta V(o))$ 라 하자. V 가 결과에 θ -의존적(비아편) 방식으로 의존하면 사후 분포는 쿨백-라이블러 사영 $\theta^\dagger \neq \theta^*$ 에 집중한다 [Berk, 1966]: 루프는 계산적으로 닫히지만 잘못된 표적에. V 의 θ -독립 아편 변환(예: 상수 가산 편향)은 로그-분배함수에서 상쇄되어 θ^* 를 바꾸지 않으며, V 가 순수 정책 채널일 때($\beta = 0$)는 어떤 검증기 변환도 표적을 옮기지 못한다—기껏해야 설계 선택을 악화시키고 정보 획득을 늦출 뿐이다(가정 1(v)와 상호작용).

증명 개요. 결합된 오설정 갱신 가능도는 사후 분포를 그 KL 최소점에 놓는다 [Berk, 1966]: 로그-분배함수 $\log \int p(o | \theta, d) e^{\beta V(o)} d\theta$ 는 그 θ -의존성이 바뀔 때만 최소점을 옮기며, θ -독립 아편 항은 이를 바꾸지 않는다. $\beta = 0$ 이면 갱신 가능도가 불변이므로 θ^* 는 V 에 불변이다. $\square$

명제 3 (신규성의 비식별성). 신규성/유의성 성분 θ_{nov} 가 식별된 성분들과 사전적으로 독립이라 하자. 모든 자동 검증기의 채널 가능도가 θ_{nov} 에 의존하지 않으면, 어떤 자동 검증기도 θ_{nov} 의 일치 추정량을 갖지 못하며, 신규성에 대한 루프 폐쇄는 V_{human} 을 요구한다.

증명 개요. 가능도가 θ_{nov} 에 의존하지 않고 사전 분포가 이를 식별된 성분과 결합하지 않으면, θ_{nov} 의 사후 주변 분포는 모든 데이터에 대해 사전 분포와 같다; 따라서 식별되지 않으며 일치 추정량이 존재하지 않는다. $\square$

이 결과들은 V 완결성 해석을 과장하지 않고 그 범위를 한정한다. 완결된 검증기는 신뢰 가능한 자율적 폐쇄(즉, 진리 추적적 보상 할당)에 필요하다—보정된 보상과, $V_{\text{empirical}}$ 의 경우 가정 1이 요구하는 식별 가능·올바르게 명세된 채널을 종종 제공한다—그러나 명제 1은 수렴이 충분한 누적 정보도 필요함을, 명제 2는 표류가 단순한 순위 변화가 아니라 잘못 결합된 검증기를 요구함을, 명제 3은 어떤 자동 검증기도 해결할 수 없는 성분을 분리해 보인다. 마지막으로 정보-최적 설계와 보상-최적 설계는 구별되어야 한다: EIG 최대화 설계와 기대 보상 최대화 설계는 기대 검증기 보상이 EIG 순서를 보존할 때에만 일치하며, 완벽히 보정된 V 에서도 어긋날 수 있다(예: $\text{EIG}(d_1) = 1 > \text{EIG}(d_2) = 0.1$ 이지만 $\mathbb{E}[V(O_{d_1})] = 0 < \mathbb{E}[V(O_{d_2})] = 10$); 보정은 어느 설계가 EIG 최적인지가 아니라 보상/정책 채널을 관장한다. 이어지는 서베이는 이 명제들을 예시하며 증명하지 않는다.

5 핵심 AI 과학자 시스템 분석

Servo를 네 개의 엔드투엔드 시스템 [Boiko et al., 2023, Lu et al., 2024, 2026, Schmidgall et al., 2025]과 하나의 아티팩트 인프라 제안에 적용한다. 표 1은 핵심 차원을 종합한다; 이 작은 표본에서 페루프 운영에 도달한 시스템들은 더 완전한 검증기를 가진 시스템이기도 하나, 이들은 $G \cdot E \cdot \pi$ 도 함께 발전시킨다(§8에서 재론).

5.1 아티팩트 인프라: 에이전트 네이티브 연구 아티팩트

Liu et al. [2026]은 상호 보완적인 문제를 다룬다: AI 과학자 루프의 출력이 어떤 모습이어야 하는지, 그리고 독립적으로 어떻게 검증될 수 있는지. 에이전트 네이티브 연구 아티팩트(ARA)는

	Robot Sci.	Coscientist	AI Sci. (2024)	AI Sci. (2026)	AgentLab	NovelSeek
신규성 측정	통계 검정	없음	LLM 자체 평가	3단계	인간 위임	성능 향상
루프 폐쇄?	예(습식)	부분적	예(탐욕적)	예(트리)	부분적	예(계산)
π 유형	능동학습	ReAct	탐욕적	트리 탐색	인간/순차	피드백
V 완결성	V_e	$V_h + V_e$	V_s (편향)	$V_e + V_s + V_h$	V_s (편향)	V_e
M 구조	$M_e + M_s$	일시적	M_e	$M_e + M_s$	M_e	M_e
H (인간 역할)	낮음	G	낮음	낮음	$G + \pi$	낮음

Table 1. 핵심 AI 과학자 시스템의 비교 Servo 분석(LLM 이전 Robot Scientist [Sparkes et al., 2010]와 최근 통합 프레임워크 NovelSeek [Zhang et al., 2025] 포함). V_s =의미, V_e =실증, V_h =인간.

서사적 논문을 네 계층의 온톨로지로 대체한다: `/logic`(반증 기준이 있는 주장), `/src`(실행 가능 코드), `/trace`(탐색 그래프: 질문, 결정, 실험, 막다른 길, 전환), `/evidence`(원시 결과). ARA 썰은 세 단계 자동 검증을 제공한다— V_{syntax} (스키마 적합성), V_{semantic} (엄격성 감사기, 82.6% 탐지율), $V_{\text{empirical}}$ (샌드박스 재현)— V_{human} 은 유의성, 신규성, 취향을 위해 명시적으로 유보된다: “유의성, 신규성, 취향에 대한 판단은 인간 심사위원을 위해 유보된다” [Liu et al., 2026]. 동기는 정량적이다: 출판 논문의 재현 요건 중 45.4%만이 완전히 명시되어 있고, 확장 비용의 90.2%는 실패한 탐색에 소비된다 [Liu et al., 2026]. `/trace` 계층은 M_e 와 M_s 를 다룬다: 보존된 실패 흔적은 에이전트의 확장 과업 성능을 가속화하지만, 동시에 더 유능한 에이전트를 이전 해결 경로에 고착시켰다—풍부한 M_e 가 π 를 단조적으로 개선하지 않는다.

6 도메인 분석

표 2은 예시적 도메인 지도다: Servo 어휘로 검증 병목이 일곱 개 과학 분야에 걸쳐 어떻게 다른지를 드러내며, 각 분야가 부딪히는 병목은 그 V 유형에서 따라 나온다(명제 1-3; 출처가 달린 도메인별 분석은 부록 B). 분석 대상 시스템: 수학(형식적: [Romera-Paredes et al., 2024, Xin et al., 2024]; 자연어: [Feng et al., 2026]), 물리학 [Udrescu and Tegmark, 2020, Cranmer et al., 2020], 화학 [Bran et al., 2024, Sprueill et al., 2024], 재료과학 [Merchant et al., 2023], 생물학 [O’Donoghue et al., 2023], 사회과학 [Manning et al., 2024, Aher et al., 2023, Park et al., 2023a], 컴퓨터 과학/알고리즘 [Real et al., 2020, Surina et al., 2025, Jaber and Jaber, 2026].

도메인	V 유형	V 신뢰도	루프	π	주요 병목
수학(형식)	V_{formal}	완벽 오라클	완전 폐쇄	RL/MCTS	사전훈련 오염
수학(자연어)	$V_{\text{sem}} + V_h$	불완전	부분적	순차 개선	환각; 표절
물리학	$V_{\text{emp}} + V_h$	중간	없음/부분적	결정론적	문제 간 M 없음
화학	V_{emp} (대리)	중간	계산만	빔 탐색	습식 루프 개방
재료과학	V_{emp} (DFT)	높음	계산 폐쇄	불확실성 샘플링	DFT 연산 시간; 합성 지연
생물학	$V_{\text{emp}} + V_h$	낮음-중간	부분적	없음	V 지표 불충분
사회과학	통계 검정	낮음-중간	부분적	완전 요인	순환 타당성
CS/알고리즘	V_{emp}	높음	완전 폐쇄	진화/LLM	해석 가능성 부재

Table 2. 일곱 개 분야에 걸친 Servo 예시적 도메인 지도(도메인별 코딩은 `domain_systems.csv`). V 신뢰도는 순서형 보정 라벨이며, 실제 정답과의 측정된 일치도가 아니다. 도메인 코딩은 인용된 1차 자료에 대한 단일 코더 해석이며; 이 표에는 코더 간 κ 통계가 없다.

도메인 패턴은 대체로 V 유형에 따라 형성된다. 수학(형식)에서, 잡음 없는 V_{formal} 은 안정적인

강화학습을 가능하게 한다: 이진적이고 명확한 보상은 해킹될 수 없다. 화학과 생물학에서, 자동화된 V 가 물리적 측정(NMR, MS, 습식 실험실 검증)을 대체할 수 없기 때문에 루프가 폐쇄될 수 없다. 재료과학은 π 가 BED 이론에 가장 근접한 유일한 도메인이다: 추적 가능한 GNN 사후 확률에 대한 GNoME의 불확실성 샘플링이 EIG 최적 탐색에 가장 가까운 현존 배포이다. 사회과학은 별개의 실패 양식에 직면한다: G 와 E 가 동일한 기반 모델을 공유할 때, 평가자는 생성기의 암묵적 편향을 체계적으로 확인한다 [Aher et al., 2023].

7 미해결 문제

본 분석은 모든 시스템과 도메인에 걸쳐 지속되는 세 가지 미해결 문제를 식별한다.

7.1 검증된 자동 신규성 게이트의 부재

현재의 어떤 자동 검증기도 신규성을 신뢰할 수 있게 평가하지 못한다: Coscientist(메커니즘 없음)에서 The AI Scientist Nature(3단계 검증)까지 모든 시스템이 이 결론으로 수렴한다. 두 가지 실패 양식이 문서화되어 있다: LLM 자체 평가 편향(체계적 과대 추정; 환각된 결과)과 사전훈련 오염(시스템이 훈련 데이터에 암묵적인 결과를 “발견”할 수 있음, Aletheia가 에르되시 문제에서 문서화한 것처럼). ARA 썰 [Liu et al., 2026]은 자동화 전선을 표시한다: 그 엄밀성 감사기(Rigor Auditor)는 5가지 구조적 위반 유형에 걸쳐 평균 82.6%를 탐지하지만, 고아 실험 위반은 22%만 탐지한다(두 비율은 서로 다른 분모를 측정하며 서로의 여사건이 아니다). 신규성 경계는 넘을 수 없다. 구체적으로: Agent Laboratory의 LLM 심사위원은 NeurIPS 심사 척도에서 인간 박사 연구원 대비 평균 +2.3점을 과대 추정했고; The AI Scientist(Sakana)는 절제 실험 표를 환각했으며; 700개의 에르되시 문제 중 인간 심사를 위해 선별된 200개의 해법 가운데 13개(6.5%)만이 의미있게 정확하다고 평가되었다. Nature급 논문에 대한 인간·AI 리뷰를 45명의 전문가가 평가한 연구도 현재 AI 리뷰어를 인간 전문가의 대체가 아니라 보완으로 자리매김한다—종합적 비평 품질은 우수하나 반복되는 사각지대를 공유하고 독립적 인간보다 서로 훨씬 더 겹친다 [Kim et al., 2026]. 이 신뢰 불가능성은 신규성 채점에 국한되지 않는다: 블랙박스 시스템을 역공학하도록—과학적 추론의 전형적 과제—요청받은 LLM은 체계적 질의 접근이 주어져도 이를 신뢰할 수 있게 수행하지 못한다 [Geng et al., 2025]. 라이텐 선언 [Alper et al., 2026]은 수학 분야에서 AI 산출 증명에 거의 보이지 않는 오류가 포함될 수 있다고 경고하며, 전문가 검토의 불가결성을 독립적으로 확인한다.

반증 기준: 자동화된 V 가 ≥ 3 개 과학 도메인에 걸친 오염-통제 벤치마크에서 인간 수준의 신규성 판별(평가자 간 일치도 ≥ 0.80)을 달성하면 반증된다; 여기서 신규성은 어휘적 훈련셋 포함을 넘어 disruption·atypicality 같은 분야 수준 척도로 조작화되어야 한다 [Park et al., 2023b, Uzzi et al., 2013].

7.2 π 의 BED-실제 격차

식 1은 이론적으로 최적인 정책을 명시하지만, 조사된 어떤 AI 과학자 시스템도 이를 구현하지 않는다: 여기서 분석한 시스템들의 모든 배포 정책은 휴리스틱이다(ReAct, 탐욕적, 트리 탐색, 인간 주도). 부분적 예외는 GNoME [Merchant et al., 2023]으로, 추적 가능한 GNN 사후 확률에 대해 EIG를 근사하는 심층 앙상블 불확실성 샘플링을 사용한다—그러나 이는 DFT가 잘 보정된 V 를 제공하고 가설 공간이 학습 가능한 확률 모델을 허용하기 때문이며, LLM 기반 시스템에는 없는 조건으로 “사후 확률”이 모델 가중치에 암묵적으로 존재한다 [Foster et al., 2021]. 최근 연구(BED-LLM [Choudhury et al., 2026])는 LLM의 예측 분포로부터 사용

가능한 EIG 사후 확률을 도출하지만 과학 실험 설계가 아니라 대화형 질의에 적용된 것이며—따라서 격차는 원천적 불가능성이 아니라 신뢰 가능한 $E \cdot V$ 와의 통합 문제이다. 구체적으로, 표 1의 모든 시스템은 휴리스틱 π 로 저하된다: Coscientist는 반응적으로 다음 도구를 선택하고, The AI Scientist(Sakana)는 탐욕적으로 아카이브 유사성을 회피하며, Agent Laboratory는 고정된 순차 스케줄을 따른다—어떤 것도 추가 실험 데이터로 개선되지 않으며, 이것이 EIG 최적 π 가 피할 실패 양식이다. 최근의 반증 주도 접근들은 자유 생성 대신 실행 가능한 검정에 가설 선택을 정박시킨다—AIGS는 자동 반박의 생존 여부로 가설을 선택하고 [Liu et al., 2024], Popper는 통계적 오류 제어를 갖춘 순차 반증 실험을 수행한다 [Huang et al., 2025]—그러나 어느 쪽도 EIG를 계산하거나 최대화하지 않는다: 이들은 BED-최적 정책을 구현하는 대신 반증 휴리스틱으로 대체한다.

반증 기준: 사후 확률이 제1원리로 추적 가능하지 않은 도메인에서 $p(\theta | y)$ 에 대한 사후 확률을 명시적으로 계산하고 EIG를 최대화하는 정책을 구현하는 AI 과학자 시스템이 있으면 반증된다—GNoME의 심층 앙상블 정책과 같은 추적 가능 모델 프록시는 제외한다.

7.3 실험 충실도 격차

Test-time compute를 통한 G 의 급속한 확장—더 많은 추론 단계, 다중 에이전트 반복, 더 큰 컨텍스트—은 구조적 비대칭을 만들었다: 가설 생성은 이제 빠르고 저렴하지만, 실험 실행 E 는 물리적으로 속도 제한이 있다. 이 비대칭에도 불구하고, 조사된 어떤 AI 과학자 시스템도 계산 proxy E 에서 물리 실험으로 언제 승격할지에 대한 원칙적 기준을 갖추고 있지 않다. 이 기준 없이는 계산 루프 폐쇄가 물리적 발견을 의미하지 않는다.

이 패턴은 표 2에서 조사된 도메인 전반에 걸쳐 일관되게 나타난다. 재료과학에서 GNoME는 DFT를 통해 38만 개의 안정 구조를 예측하지만 [Merchant et al., 2023], 736개만이 독립적으로 실험 실현되었다 [Cheetham and Seshadri, 2024]: 계산적으로 안정한 어떤 구조를 물리적 합성에 투자할지 결정하는 것은 외부에서 이루어지며, 원칙적 자동화가 없다. 화학에서 ChemCrow와 ChemReasoner는 계산 루프를 닫지만, 측정 경계에서 습식 실험실 루프를 열어 둔다: NMR 및 MS 특성화는 어떤 현재 시스템도 언제 호출할지 알지 못하는 물리적 실험을 요구한다 [Gromski et al., 2019]. 생물학에서, BioPlanner는 프로토콜을 생성하지만 V 지표가 루프를 자율적으로 닫기에 불충분하다 [O’Donoghue et al., 2023]—물리적 실험 질문에 도달하지 못한다. GNoME가 가장 성공적인 사례인 것은 바로 E 를 단일 충실도 수준(DFT)으로 고정하고 그 제약 안에서 최적화하기 때문이다: 이는 승격 문제를 해결하는 것이 아니라 우회하는 것이다.

최근의 자율 “자가 구동(self-driving)” 실험실들은 이 격차에 직접 관련되지만 그것을 닫지는 못한다. 재료과학에서 A-Lab [Szymanski et al., 2023]은 계산 스크리닝을 로봇 합성에 결합하여 57개 표적 화합물 중 36개를 실현했다고 보고되지만, 물리적 검증이 언제 정당화되는지에 대한 증거 기반 기준이 아니라 고정된 스크리닝-후-합성 규칙으로 승격한다. ORGANA [Darvish et al., 2024] 같은 로봇 화학 플랫폼은 습식 실험의 물리적 실험을 자동화하고, AutoLabs [Panapitiya et al., 2025] 같은 자기수정 다중 에이전트 시스템은 하드웨어-레디 프로토콜의 생성을 자동화한다; 리뷰들은 기저 하드웨어의 급속한 성숙을 기록한다 [Tobias and Wahab, 2025]. 그러나 E 를 자동화하는 것은 역량을 제공할 뿐 기준을 제공하지 않는다: 이 시스템들은 고정되거나 외부에서 선택된 충실도에서 작동하며, 누적된 계산 증거가 물리적 assay로의 승격을 언제 정당화하는지를 결정하지 않는다. 따라서 병목은 하드웨어 자동화와 직교한다—물리적 루프가 기계적으로 실행 가능해져도 지속된다.

Test-time scaling은 이 격차를 해소하지 못한다. 더 많은 추론 단계는 DFT 벽시계 시간, 습식 실험실 처리 시간, 합성 지연을 줄일 수 없다; 이는 E 에 대한 물리적 제약이지 계산적 제약이

아니다. 이 격차는 기존 결과 캐싱이나 검색 메커니즘으로도 이미 해결되지 않는다: 이들은 과거 실험 결과를 축적하지만 더 높은 충실도 측정에 언제 투자할지를 결정하지는 않는다. 누락된 구성요소는 계산적 증거가 축적됨에 따라 그 증거가 물리적 검증 비용을 정당화하기에 충분한지를 결정하는 기준이다—그리고 충분하지 않다면, 어떤 추가적인 계산 실험이 가장 효율적으로 격차를 좁힐지를 결정하는 기준이다.

이 문제는 Op1·Op2와 구조적으로 구별된다. 완전한 V 는 신규성을 평가할 수 있다—그러나 입력으로 받는 충실도 수준에서만. EIG-최적 π 는 다음에 검정할 가설을 선택한다—그러나 현재 이용 가능한 충실도의 실험들 사이에서. E 승격 기준 없이는 시스템이 신뢰할 만한 과학적 주장에 필요한 물리적 증거에 도달하지 않은 채 계산 루프를 무한정 닫을 수 있다. 세 미해결 문제는 따라서 순차적으로 상호작용한다: V 는 각 충실도에서 보상을 보정하고; π 는 탐색 예산을 배분하며; E 승격 기준은 계산 루프를 물리적 발견으로 연결하기로 결정한다.

반증 기준: 이 격차는 누적 계산 증거에 기반한 물리 실험 승격 기준을 구현해, 고정 승격 시스템보다 단위 물리 실험 비용당 검증된 발견 비율이 높은 시스템이 있으면 반증된다.

핵심 설계 질문은 두 가지다: 계산 증거가 얼마나 확신적이어야 물리 승격이 정당화되는가, 그리고 오라클 보정 오차(예: DFT 근사치)를 임계값에 어떻게 반영할 것인가? 어떤 현재 AI 과학자 시스템도 이에 대한 원칙적 답을 갖지 않는다.

세 미해결 문제는 순차적 의존 관계를 형성한다: 완전한 V 가 각 충실도 수준의 보상을 보정하고 → EIG-최적 π 가 가설 우선순위를 결정하며 → E 충실도 기준이 계산 루프를 물리적 발견으로 연결한다. V 없이는 계산적 증거가 충분한지 판단할 수 없어 조기 또는 지연 승격으로 이어진다; 휴리스틱 π 는 최적이지 아닌 가설에 승격 예산을 낭비한다; E 기준 없이는 루프가 계산적으로는 닫히나 물리적으로 실현되지 않는다.

8 논의

검증기 설계는 제약으로서. 분석은 V 설계가 신뢰 가능한 페루프 운영의 필요 제약으로 보임을 시사한다: 신뢰할 수 없는 검증은 시스템이 자신의 출력이 진전을 나타내는지 학습하지 못하게 한다. 조사된 시스템들은 V 를 G , E , M , π 와 분리하지 않으므로, 우리는 V 완결성을 인과적으로 확립된 우선순위가 아니라 반복되는 병목으로 읽는다. 이 어휘는 진단적 질문을 제기한다: G 나 π 를 최적화하기 전에 해당 도메인이 어떤 수준의 V 완결성을 실제로 지원하는가? 이것은 어휘의 실패 모드 국소화 능력에서 도출된 가설-생성 프레임이지, 보정과 신뢰 가능한 폐쇄 간의 경험적 연관이 잠정적 구조화 주석에 그치기 때문에 증거 기반 설계 권고가 아니다. 동시에, V -완결성과 BED-최적 π 는 서로 다른 목표의 필요 제약이다: 신뢰 가능한 폐쇄는 보정된 검증기를 요구하지만, 과학적으로 가치 있는 폐쇄— S 의 진정으로 미탐색 영역에 도달하는 것—는 이미 착취된 전선을 벗어나는 탐색 정책을 요구한다. 현재 시스템들은 두 가지 모두에서 부족하며, 실패 양식은 서로 환원되지 않는다.

인간 감독. $H \in [0, 1]$ 을 최소화할 양으로 취급하는 대신, 분석은 V_{human} 및 π 수준에서의 명시적 인간 통합이 실질적으로 필요하고 이론적으로도 적절함을 시사한다.

집합적 AI 공동 과학자를 향하여. 집합적 확장 [Taniguchi et al., 2025]은 세 미해결 문제가 먼저 해결될 것을 요구한다. 이러한 집합체는 인식론적 다양성도 보존해야 한다: AI 리뷰어는 이미 인간보다 서로 훨씬 더 겹치며 [Kim et al., 2026], 인식 공동체에 이로운 일시적 다양성을 잃을 위험이 있다 [Zollman, 2010]. 라이덴 선언 [Alper et al., 2026]은 복합 위험을 식별한다: AI 시스템이 자동 검증에 적합한 문제를 표적으로 삼으면서, 집합적 탐색이 점점 좁아지는 전선에 집중되고 필드 수준에서 S 가 왜곡될 수 있다.

한계. Servo은 E 의 도메인 특화 비용 구조(도메인에 따라 수십 배 차이), S 의 비정상성(개방형 문제), 그리고 Taniguchi et al. [2025]가 형식화한 사회적 계층을 추상화한다. 더 근본적으로 V -완결성 패턴은 인과적 결정 요인이 아니라 시스템 간 연관이며, 조사된 시스템은 선택·생존 편향이 있는 편의 표본이다. 또한 기계적 루프 폐쇄는 완결성을 요구하지 않으며(AI Scientist v1과 NovelSeek는 낮은 완결성에서도 계산적 루프를 닫는다), 따라서 우리의 주장은 신뢰 가능한 폐쇄에 관한 것인데 이를 V 와 독립적으로 측정하지 않았으므로 검증기/신뢰성 관계를 검증된 연관이 아니라 조직화 가설로 제시한다. 교차 시스템 코딩 방법론, 공개 아티팩트(루브릭·행별 출처 인용문·인용 검증 스크립트), 다중 벤더 신뢰도 추정치는 부록 A에 상술한다; 요약하면, 서로 다른 벤더(Anthropic·OpenAI·Google)의 블라인드 모델 고정 LLM 코더 3개가 중심 주장이 기대는 보정 하위 구성개념에서는 상당히 일치하나(Fleiss' $\kappa=0.79$) 전체론적 V -완결성 순서형에서는 약하게만 일치하며($\kappa=0.39$), 어떤 시스템도 보정된 자동 신규성 게이트를 갖지 않는다—모두 인간 수준이 아닌 자동 투명성 지표로 보고한다. 검증자가 신뢰할 수 없다고 우리가 주장하는 시스템들을 LLM 코더로 특성화한 것 자체가 반성적 한계다—코딩이 스스로 기록하는 편향을 물려받을 수 있다—그래서 중심 주장을 LLM-코딩된 V -완결성 순서형이 아니라 보정 하위 구성개념에 고정했으며, 인간 전문가 코딩은 필요한 향후 과제로 남는다.

9 결론

본 논문은 AI 과학자 시스템을 POMDP 및 BED 이론과 연결하는 형식 프레임워크인 Servo (S, G, E, V, M, π)를 도입하고, 이를 여섯 개의 핵심 시스템, 하나의 아티팩트 인프라 제안, 일곱 개 과학 도메인에 적용했다. 명제 1-3는 더 좁은 주장만을 뒷받침하여, V 완결성이 실제 시스템 전반의 주된 결정 요인임을 증명하기보다 관측·보상 검증·인간 신규성 판단의 분리를 동기화한다; 게이팅 보정이 신뢰 가능한 폐쇄와 연결된다는 조직화 가설은 검증된 발견이 아니라 잠정적 구조화 주석으로 남는다(보충 자료). Servo이 제공하는 것은 남은 병목—검증기 완결성, 탐색 정책 설계, 실험 충실도 승격—을 닫는 데 필요한 것을 정확히 명명하는 어휘다.

References

- G. V. Aher, R. I. Arriaga, and A. T. Kalai. Using large language models to simulate multiple humans and replicate human subject studies. In International Conference on Machine Learning, 2023. arXiv:2208.10264.
- J. Alper, M. Barany, A. Chavarri Villarello, S. Dahmen, W. Dean, K. Ganapathy, M. Harris, D. Holmes, M. Jamnik, S. Kelk, B. Kra, U. Martin, B. Naskręcki, R. Ochigame, J. Portegies, and J. Schmitt. Leiden declaration on artificial intelligence and mathematics. <https://leidendeclaration.ai>, June 2026.
- J. Baek, S. K. Jauhar, S. Pitis, S. J. Hwang, and J. Teevan. ResearchAgent: Iterative research idea generation over scientific literature with large language models. arXiv preprint arXiv:2404.07738, 2024.
- R. H. Berk. Limiting behavior of posterior distributions when the model is incorrect. The Annals of Mathematical Statistics, 37(1):51–58, 1966.
- T. Blau, E. V. Bonilla, I. Chades, and A. Dezfouli. Optimizing sequential experimental design with deep reinforcement learning. In International Conference on Machine Learning, 2022. arXiv:2202.00821.
- D. A. Boiko, R. MacKnight, B. Kline, and G. Gomes. Emergent autonomous scientific research capabilities of large language models. Nature, 624:570–578, 2023.

- A. M. Bran, S. Cox, O. Schilter, C. Baldassari, A. D. White, and P. Schwaller. ChemCrow: Augmenting large-language models with chemistry tools. *Nature Machine Intelligence*, 2024. arXiv:2304.05376.
- K. Chaloner and I. Verdinelli. Bayesian experimental design: A review. *Statistical Science*, 10(3):273–304, 1995.
- A. K. Cheetham and R. Seshadri. Artificial intelligence driving materials discovery? Perspective on the article: Scaling deep learning for materials discovery. *Chemistry of Materials*, 36, 2024. doi: 10.1021/acs.chemmater.4c00643. Available: <https://escholarship.org/content/qt9qx9t3kz/qt9qx9t3kz.pdf>.
- D. Choudhury, S. Williamson, A. Goliński, N. Miao, F. B. Smith, M. Kirchhof, Y. Zhang, and T. Rainforth. BED-LLM: Intelligent information gathering with LLMs and Bayesian experimental design. In *International Conference on Learning Representations*, 2026. arXiv:2508.21184.
- M. Cranmer, A. Sanchez Gonzalez, P. Battaglia, R. Xu, K. Cranmer, D. Spergel, and S. Ho. Discovering symbolic models from deep learning with inductive biases. In *Advances in Neural Information Processing Systems*, 2020. arXiv:2006.11287.
- K. Darvish, M. Skreta, Y. Zhao, N. Yoshikawa, S. Som, M. Bogdanovic, Y. Cao, H. Hao, H. Xu, A. Aspuru-Guzik, A. Garg, and F. Shkurti. ORGANA: A robotic assistant for automated chemistry experimentation and characterization, 2024. arXiv:2401.06949; also in *Matter* (Cell Press) 2025.
- T. Feng, Q. V. Le, T. Luong, T. H. Trinh, G. Bingham, D. Hwang, Y. Chervonyi, et al. Towards autonomous mathematics research. arXiv preprint arXiv:2602.10177, 2026. arXiv:2602.10177.
- A. Foster, M. Jankowiak, E. Bingham, P. Horsfall, Y. W. Teh, T. Rainforth, and N. Goodman. Variational Bayesian optimal experimental design. In *Advances in Neural Information Processing Systems*, 2019. arXiv:1903.05480.
- A. Foster, D. R. Ivanova, I. Malik, and T. Rainforth. Deep adaptive design: Amortizing sequential Bayesian experimental design. In *International Conference on Machine Learning*, 2021. arXiv:2103.02438.
- J. Geng, H. Chen, D. Arumugam, and T. L. Griffiths. Are large language models reliable AI scientists? assessing reverse-engineering of black-box systems, 2025. arXiv:2505.17968.
- S. Ghosal and A. van der Vaart. *Fundamentals of Nonparametric Bayesian Inference*. Cambridge Series in Statistical and Probabilistic Mathematics. Cambridge University Press, 2017.
- J. Gottweis, W.-H. Weng, A. Daryin, T. Tu, P. Sirkovic, A. Myaskovsky, G. Glowatyj, F. Weissenberger, A. Orlandi, D. Popovici, et al. Accelerating scientific discovery with Co-Scientist. *Nature*, 2026. doi: 10.1038/s41586-026-10644-y. arXiv:2502.18864.
- P. S. Gromski, A. B. Henson, J. M. Granda, and L. Cronin. How to explore chemical space using algorithms and automation. *Nature Reviews Chemistry*, 3:119–128, 2019. doi: 10.1038/s41570-018-0066-y.
- X. Gu and M. Krenn. Interesting scientific idea generation using knowledge graphs and LLMs: Evaluations with 100 research group leaders. arXiv preprint arXiv:2405.17044, 2024. arXiv:2405.17044.

- K. Huang, Y. Jin, R. Li, M. Y. Li, E. Candès, and J. Leskovec. Automated hypothesis validation with agentic sequential falsifications, 2025. arXiv:2502.09858; ICML 2025.
- J. Jaber and O. Jaber. AutoKernel: Autonomous GPU kernel optimization via iterative agent-driven search. arXiv preprint arXiv:2603.21331, 2026.
- J. Jumper, R. Evans, A. Pritzel, T. Green, M. Figurnov, O. Ronneberger, K. Tunyasuvunakool, R. Bates, A. Židek, A. Potapenko, et al. Highly accurate protein structure prediction with AlphaFold. *Nature*, 596:583–589, 2021.
- L. P. Kaelbling, M. L. Littman, and A. R. Cassandra. Planning and acting in partially observable stochastic domains. *Artificial Intelligence*, 101(1-2):99–134, 1998.
- S. Kim, D. Yoon, K. Gashteovski, J. Suk, J. Baek, P. Aggarwal, I. Wu, et al. On the limits and opportunities of AI reviewers: Reviewing the reviews of Nature-family papers with 45 expert scientists. arXiv preprint arXiv:2605.20668, 2026.
- M. Lee, S. Hwang, S. Moon, G. Nah, D. Koh, Y. Cho, J. Park, H. Yoo, J. Park, H. Choi, S. Moon, T. Hwang, S. Kim, J. Kim, S. Kim, and J. Jung. Spacer: Towards engineered scientific inspiration. arXiv preprint arXiv:2508.17661, 2025. arXiv:2508.17661.
- J. Liu et al. The last human-written paper: Agent-Native research artifacts. arXiv preprint arXiv:2604.24658, 2026. arXiv:2604.24658.
- Z. Liu, K. Liu, Y. Zhu, X. Lei, Z. Yang, Z. Zhang, P. Li, and Y. Liu. AIGS: Generating science from AI-powered automated falsification, 2024. arXiv:2411.11910.
- C. Lu, C. Lu, R. T. Lange, J. Foerster, J. Clune, and D. Ha. The AI Scientist: Towards fully automated open-ended scientific discovery. arXiv preprint arXiv:2408.06292, 2024.
- C. Lu, C. Lu, R. T. Lange, Y. Yamada, S. Hu, J. Foerster, D. Ha, and J. Clune. Towards end-to-end automation of AI research. *Nature*, 651:914–919, 2026. doi: 10.1038/s41586-026-10265-5.
- B. S. Manning, K. Zhu, and J. J. Horton. Automated social science: Language models as scientist and subjects. Working Paper 32381, National Bureau of Economic Research, 2024. arXiv:2404.11794.
- A. Merchant, S. Batzner, S. S. Schoenholz, M. Aykol, G. Cheon, and E. D. Cubuk. Scaling deep learning for materials discovery. *Nature*, 624:80–85, 2023.
- O. O’Donoghue, G. Puthumanam, J. Won, P. Moura, M. Oettig, J. M. de Kruif, M. Gini, M. Heinonen, and P. Sloom. BioPlanner: Automatic evaluation of LLMs on protocol planning in biology. arXiv preprint arXiv:2310.10632, 2023.
- G. Panapitiya, E. Saldanha, H. Job, and O. Hess. AutoLabs: Cognitive multi-agent systems with self-correction for autonomous chemical experimentation, 2025. arXiv:2509.25651.
- J. S. Park, J. C. O’Brien, C. J. Cai, M. R. Morris, P. Liang, and M. S. Bernstein. Generative agents: Interactive simulacra of human behavior. In *Proceedings of the ACM Symposium on User Interface Software and Technology*, 2023a. arXiv:2304.03442.
- M. Park, E. Leahey, and R. J. Funk. Papers and patents are becoming less disruptive over time. *Nature*, 613:138–144, 2023b. doi: 10.1038/s41586-022-05543-x.
- T. Rainforth, A. Foster, D. R. Ivanova, and F. B. Smith. Modern Bayesian experimental design. *Statistical Science*, 2024. arXiv:2302.14545.
- E. Real, C. Liang, D. So, and Q. Le. AutoML-Zero: Evolving machine learning al-

- gorithms from scratch. In International Conference on Machine Learning, 2020. arXiv:2003.03384.
- B. Romera-Paredes, M. Barekatain, A. Novikov, M. Balog, M. P. Kumar, E. Dupont, F. J. R. Ruiz, J. Ellenberg, P. Wang, O. Fawzi, et al. Mathematical discoveries from program search with large language models. *Nature*, 625:468–475, 2024.
- S. Schmidgall, Y. Su, Z. Wang, X. Sun, J. Wu, X. Yu, J. Liu, and E. Barsoum. Agent Laboratory: Using LLM agents as research assistants. arXiv preprint arXiv:2501.04227, 2025.
- C. Si, D. Yang, and T. Hashimoto. Can LLMs generate novel research ideas? A large-scale human study with 100+ NLP researchers. arXiv preprint arXiv:2409.04109, 2024.
- A. Sparkes, W. Aubrey, E. Byrne, A. Clare, M. N. Khan, M. Liakata, M. Markham, J. Rowland, L. N. Soldatova, K. E. Whelan, M. Young, and R. D. King. Towards robot scientists for autonomous scientific discovery. *Automated Experimentation*, 2(1):1, 2010. doi: 10.1186/1759-4499-2-1.
- H. W. Sprueill, C. Edwards, K. Agarwal, M. Olarte, U. Sanyal, C. Johnston, H. Liu, H. Ji, and S. Bhatt. ChemReasoner: Heuristic search over a large language model’s knowledge space using quantum-chemical feedback. In International Conference on Machine Learning, 2024. arXiv:2402.10980.
- A. Surina, A. Mansouri, L. Quaedvlieg, A. Seddas, M. Viazovska, E. Abbe, and C. Gulcehre. Algorithm discovery with LLMs: Evolutionary search meets reinforcement learning. arXiv preprint arXiv:2504.05108, 2025.
- N. J. Szymanski, B. Rendy, Y. Fei, R. E. Kumar, T. He, D. Milsted, M. J. McDermott, M. Gallant, E. D. Cubuk, A. Merchant, H. Kim, A. Jain, C. J. Bartel, K. Persson, Y. Zeng, and G. Ceder. An autonomous laboratory for the accelerated synthesis of inorganic materials. *Nature*, 624:86–91, 2023. doi: 10.1038/s41586-023-06734-w.
- T. Taniguchi, S. Takagi, J. Otsuka, Y. Hayashi, and H. T. Hamada. Collective predictive coding as model of science: Formalizing scientific activities towards generative science. *Royal Society Open Science*, 12(6):241678, 2025. doi: 10.1098/rsos.241678. arXiv:2409.00102.
- A. V. Tobias and A. Wahab. Autonomous ‘self-driving’ laboratories: a review of technology and policy implications. *Royal Society Open Science*, 12(7):250646, 2025. doi: 10.1098/rsos.250646.
- S.-M. Udrescu and M. Tegmark. AI Feynman: A physics-inspired method for symbolic regression. *Science Advances*, 6(16):eaay2631, 2020.
- B. Uzzi, S. Mukherjee, M. Stringer, and B. Jones. Atypical combinations and scientific impact. *Science*, 342(6157):468–472, 2013. doi: 10.1126/science.1240474.
- H. Xin, Z. Z. Ren, J. Song, Z. Shao, W. Zhao, H. Wang, B. Liu, L. Zhang, et al. DeepSeek-Prover-V1.5: Harnessing proof assistant feedback for reinforcement learning and Monte-Carlo tree search. arXiv preprint arXiv:2408.08152, 2024. arXiv:2408.08152.
- B. Zhang, S. Feng, X. Yan, J. Yuan, Z. Yu, S. Huang, L. Bai, X. He, T. Peng, et al. NovelSeek: When agent becomes the scientist – building closed-loop system from hypothesis to verification. arXiv preprint arXiv:2505.16938, 2025. arXiv:2505.16938.
- K. J. S. Zollman. The epistemic benefit of transient diversity. *Erkenntnis*, 72(1):

17-35, 2010.

AI 참여 체크리스트

이 체크리스트는 CAISc 2026이 요구하는 대로 이 연구의 각 단계에서 AI 시스템의 역할을 문서화한다.

- **가설 개발.** 핵심 Servo 프레임워크 (S, G, E, V, M, π), H 매개변수, G 출력 스펙트럼(명제 가설 $\rightarrow$ 반증 가능한 구성), 세 가지 미해결 문제는 인간 저자가 구상했다. Claude Code(Anthropic)는 프레임워크 구성요소를 정교화하고, 각 구성요소의 논문 수준 구체화를 식별하며, 개념 간 연결을 제안했다.
- **문헌 검색 및 선택.** 인간 저자가 포함 기준과 대상 시스템을 결정했다. Claude Code는 자율적으로 40개 이상의 전문 PDF를 검색, 열람하고, 논문들을 분류학으로 범주화하며, 원문 대비 주장 수준의 검증을 수행했다.
- **분석.** Claude Code는 1차 자료를 읽어 13개 분석 시스템 각각의 S, G, E, V, M, π 구성요소를 추출했다. 인간 저자는 모든 추출을 검토하고, 오류를 수정(여러 실질적 수정이 필요했음)하며, 교차 시스템 패턴을 종합했다. 본 venue의 전제에 부합하게, 교차 시스템 코딩은 인간 지시 하의 AI 수행이며 그 사실을 명시한다; 그 엄밀성은 독립적 인간 gold standard가 아니라 감사가능성(공개된 루브릭·행별 출처 인용문·재생성/인용 검증 스크립트)과 보수적 주장 범위 한정에 근거하며, 인간 검증 연구는 프레임워크 기여와 직교한다고 보아 향후 과제로 남긴다.
- **작성.** Claude Code가 이 원고의 대부분을 초안 작성했다. 인간 저자는 핵심 개념적 단락(특히 §7 및 §4의 핵심 정의)을 제공하고, 구조적 결정을 지시하며, 모든 초안을 검토했다.

전반적으로, 분업의 특성은 다음과 같다: 인간 저자는 지적 방향, 프레임워크 설계, 최종 판단을 제공했고; Claude Code는 문헌 검색, 분석 실행, 텍스트 생성을 담당했다.

책임 및 재현성 체크리스트

- **주장과 증거.** 모든 경험적 주장은 인용된 1차 자료에 근거한다. 주요 주장은 원본 PDF의 직접 전문 열람으로 검증되었다.
- **한계.** 이 논문은 기존 출판 시스템의 개념적 메타 분석이다. 독창적인 실험을 포함하지 않는다. Servo 프레임워크는 이 제출에서 보류 시스템에 대해 경험적으로 검증되지 않았으며; 기술적 적절성은 분석된 13개 시스템 전반의 일관성에 달려있다.
- **재현성.** 시스템 선택과 구성요소 추출 방법은 조작적 코딩 프로토콜로 문서화되며, 시스템별 대표 출처 인용문이 달린 기계가독 코딩 시트, 서로 다른 벤더의 모델 고정 LLM 평가자 3개에 의한 14개 시스템 다중벤더 블라인드 코딩과 Fleiss' κ , 반례 탐색, 표 재생성·검증 스크립트를 보충 자료로 공개한다. Servo은 구성요소 정의에 따라 어떤 AI 과학자 시스템에도 적용될 수 있으며, 분석된 모든 논문은 공개적으로 접근 가능하다. 독점 데이터나 비공개 모델은 사용되지 않았다.
- **실험 세부사항.** 문헌 검토 방법론은 Muka et al. (2020) 24단계 체계적 검토 지침을 따른다. 시스템 선택 기준: 가설-실험-검증 루프의 최소 하나의 구성요소를 자동화한다.
- **데이터 및 코드 가용성.** 코딩 프로토콜(coding_protocol.md), 핵심 시스템(systems.csv)과 일곱 개 도메인 표 2(domain_systems.csv) 양쪽에 대해 출처 인용이 달린 코딩 시트, 다중 벤더 보정 재코딩(multicoder/), 신뢰도 보고서(reliability_report.md), 기계적/신뢰 폐쇄 기술 분석(trustworthy_closure.md, association_descriptive.py), 인용 검증·표 재생성 스크립트(build_servo_tables.py, build_domain_tables.py, compute_calib.py)를 analysis/ 디렉터리로 공개한다. 별도 데이터셋은 생성되지 않았다.
- **윤리적 및 사회적 영향.** H 매개변수 분석은 현재 시스템에서 인간 감독의 필요성을 명시적으로 다룬다. §7의 미해결 문제 논의는 AI 과학자 광범위 배포 하의 조기 수렴 위험을 식별하며, 특히 실험 충실도 격차 및 신규성 비자동화 문제를 통해.

A 교차 시스템 코딩 신뢰도

교차 시스템 서베이는 잠정적 구조화 주석으로 공개한다. 주장은 신뢰 가능한 폐쇄에 관한 것이며 이를 V 와 독립적으로 측정하지 않는다: trustworthy_closure 코딩은 V 와 부분적으로만 독립인 결과 신호에 의존하고(동료심사·게재는 V_{human} 과 겹친다), 6개 시스템이고 결과가 V 와 얽혀 있어 방향을 검정할 수 없다. 코딩을 감사 가능하게 하기 위해 우리는 조작적 루브릭, 핵심 시스템과 교차 도메인 표 2 양쪽에 대해 행별 대표 출처 인용문과 인용 키가 달린 기계가독 코딩 시트, 인용이나 인용문이 없는 행을 거부하는 검증 스크립트를 공개한다.

서로 다른 벤더의 모델 고정 블라인드 LLM 기반 코더 에이전트 3개—Claude Code(claude-opus-4-8, Anthropic), Codex CLI(gpt-5.5, OpenAI), Antigravity(gemini-3.1-pro, Google), 모두 헤드리스·모델 고정이며 정확한 호출과 모델별 출력은 보충 자료에 공개—가 14개 시스템을 코딩했으며, 코더 간 일치(전원이 코딩한 13개 시스템에 대한 Fleiss' κ)는 대부분 구성개념에서 상당 완전(보정 $\kappa=0.79$, 루프 상태 $\kappa=0.74$, 의미검증 존재 $\kappa=1.0$; 평균 $\kappa=0.68$)이고 전체론적 V -완결성 순서형에서만 약한(fair) 수준($\kappa=0.39$; Landis-Koch 기준 0.21-0.40, 이 항목은 AI 산출 참조 라벨과도 불일치)이며, 인간 수준 신뢰도가 아닌 자동 다중평가자 투명성 지표로 보고한다. 반례 탐색은 V -불완전하면서 신뢰 가능한 페루프 발견을 달성하는 시스템을 찾지

못했다: 유일한 구조적 근접 사례(AI Scientist v1)는 편향된 검증기 위에서 루프를 닫지만 신뢰할 수 없는 출력을 낸다.

코더들은 참조 라벨(인간 지시 하의 AI 산출, 보충자료의 Coder A; 인간 gold standard 아님)과 AI Scientist(Nature 2026)의 검증기 “보정” 여부를 두고 갈렸는데—옛 라벨이 보정 계층의 존재와 게이팅 계층의 보정을 뭉친 것이다. 이 분할을 14개 시스템 전체에 대해 재코딩하면(2개 벤더; 보충 자료) 불일치가 해소되고(참조 라벨과 두 코더 모두 계층이 존재하나 게이팅하지 않음에 합의), 게이팅 보정이 더 명확히 특정되며(raw 일치 13/14, Cohen $\kappa=0.86$; 인간 검증이 아닌 자동 견고성 점검), 어떤 시스템도 보정된 자동 신규성 게이트를 갖지 않아 신규성 미해결 문제를 실증한다. $V_{\text{present}}/V_{\text{gating}}$ 분리는 단일 코더-저자 불일치 발견 이후 사후적으로 도입되었으며, $\kappa=0.86$ 은 전향적 신뢰도 연구가 아니라 이 반복적 구성개념 정제 과정을 반영한다.

B 도메인별 분석

이 부록은 표 2을 Servo 어휘에 따른 도메인별 독해로 확장하여, 각 분야에 대해 검증기 유형과 그 신뢰도, 그 검증기가 허용하는 루프 상태, 실제 배포된 탐색 정책, 그리고 그로부터 따라 나오는 병목을 기술한다. 코딩은 행별 대표 출처 인용문과 인용 키와 함께 기계가독 domain_systems.csv로 공개되며, 아래 항목들은 그 인용문을 풀어 쓴 것으로 독립적 경험 연구가 아니라 인용 문헌의 구조화된 독해로 읽어야 한다.

수학, 형식적 (V_{formal} ; 완전 폐쇄). FunSearch [Romera-Paredes et al., 2024]와 DeepSeek-Prover [Xin et al., 2024]는 형식적·수치적 오라클(평가 함수 또는 증명 커널)로 결정적 통과/실패를 반환받아 검증한다. 이 V_{formal} 은 가정 1의 의미에서 완전한 오라클이므로 보상 채널이 정확히 보정되고 RL/MCTS 탐색이 안정적이며, 루프는 완전히 닫힌다. 잔여 병목은 검증이 아니라 S 다: 사전학습 오염으로 인해 “발견된” 결과가 암기가 아닌 진짜 신규임을 입증하기 어려우며, 이는 신규성 문제(명제 3)의 형식 도메인 사례다.

수학, 자연어 ($V_{\text{sem}} + V_h$; 낮은 품질로 폐쇄). Aletheia [Feng et al., 2026]는 LLM·인간 판단으로 채점되는 자연어 증명을 생성한다. 루프는 기계적으로 닫히나 V_{sem} 이 불완전하다: 감사된 200개 예르되시 해법 중 13개(6.5%)만이 의미있게 정확하다고 평가됐다. 형식 오라클을 의미 오라클로 대체하면 V_h 가 재도입되고 환각과 표절이 실패 양식으로 노출되는데, 이는 잘못 보정된 보상 채널이 표류를 허용함을 보여주는 사례다(명제 2). 라이덴 선언 [Alper et al., 2026]은 실무자 측면에서 이를 뒷받침한다: AI 산출 자연어 증명은 전문가 검토 없이는 탐지가 어려운 거의 보이지 않는 오류를 포함할 수 있어, 자동화된 검사가 존재하는 도메인에서도 V_{human} 이 대체 불가능함을 강조한다.

물리학 ($V_{\text{emp}} + V_h$; 없음/부분). AI Feynman [Udrescu and Tegmark, 2020]과 기호 모델 발견 [Cranmer et al., 2020]은 결정적 탐색으로 데이터에 방정식을 적합한다. 검증은 경험적이고 중간 신뢰도이나, 문제 간 메모리 전이가 없어 각 과제가 처음부터 시작된다. 따라서 병목은 문제 간 메모리 전이의 부재다: 각 과제가 이전 발견의 축적된 패턴 없이 처음부터 시작된다.

화학 (V_{emp} 대리; 계산 루프만). ChemCrow [Bran et al., 2024]와 ChemReasoner [Sprueill et al., 2024]는 대리 신호로 계산적으로 검증하며 빔 탐색을 쓴다. 계산 루프는 닫히나 물리적

특성 분석(NMR, MS)이 습식 실험실 루프를 열어 둔다: 실제 발견을 확인할 검증기가 자동화 경계 밖에 있어 측정 접점에서 폐쇄가 부분적이다.

재료과학 (V_{emp} , DFT; 계산적으로 폐쇄). GNoME [Merchant et al., 2023]은 DFT-인-더-루프 능동학습으로 상안정성 예측을 위한 계산 루프를 닫아 220만 개 후보 구조(38만 개 안정)를 예측한다. DFT는 물리적 에너지의 근사치이지 완전히 보정된 경험적 오라클이 아니며, 예측된 안정 구조 대부분은 여전히 합성·특성화·기능 검증이 필요하다 [Cheetham and Seshadri, 2024]. Servo는 재료과학을 DFT 상안정성 스크리닝에 대해서만 계산적으로 폐쇄된 것으로 코딩한다. DFT가 비교적 신뢰할 만하고 불확실성 샘플링이 정책을 이끌기 때문에, 이는 π 가 BED 이상에 가장 근접한 유일한 조사 도메인이다. 병목은 자원적이다: DFT 벽시계 시간과 예측 구조가 합성되기까지의 지연.

생물학 ($V_{\text{emp}} + V_h$; 부분). BioPlanner [O'Donoghue et al., 2023]은 실험 프로토콜을 생성하나 검증 신호가 약하고 생물학적 타당성 지표가 루프를 자율적으로 닫기에 불충분하여, 신뢰도가 낮음 중간이고 생성 외의 탐색 정책이 사실상 없다. 병목은 V 자체다: 실제 생물학적 타당성을 추적하는 지표 없이는 신뢰 가능한 무언가로 루프를 닫을 수 없다.

사회과학 (통계 검증; 부분). 자동 사회과학 파이프라인 [Manning et al., 2024]과 LLM 시뮬레이션 연구 [Aher et al., 2023, Park et al., 2023a]는 완전 요인 설계에 대한 통계 검정으로 검증한다. 특징적 실패는 순환 타당성이다: 생성기 G 와 시뮬레이션 대상이 모델을 공유하면 검증기는 외부 사실이 아니라 모델의 자기일관성을 측정한다 [Aher et al., 2023]—이는 가정 1의 식별 채널 조건 위반이다.

컴퓨터 과학 / 알고리즘 (V_{emp} ; 완전 폐쇄). AutoML-Zero [Real et al., 2020], 알고리즘 발견 [Surina et al., 2025], AutoKernel [Jaber and Jaber, 2026]은 신뢰할 만한 벤치마크·경험적 검증과 진화적·LLM 유도 탐색으로 루프를 닫는다. 검증은 고신뢰도이고 루프는 완전히 닫히며, 잔여 병목은 해석가능성이다—발견된 산물은 작동하나 인간 이해를 거부하며, 이는 V 가 아니라 M -출력 형식의 한계다.

교차 도메인 독해. 각 분야가 부딪히는 병목은 대체로 그 V 유형의 함수다: 완전한 형식 오라클은 오염에 제약되는 완전 폐쇄 루프를, 불완전한 의미·경험 V 는 환각·순환 타당성·지표 불충분 실패를, 신뢰할 만하나 비싼 경험적 오라클(재료)은 병목을 인식론에서 자원으로 옮긴다. 이것이 표 2의 진단적 용법이다: 검정된 교차 도메인 법칙을 주장하지 않으며, 동일한 (S, G, E, V, M, π) 어휘가 각 도메인의 루프가 어디서 무너지는지를 국소화함을 보인다. V 유형은 도메인의 루프가 신뢰 가능하게 닫힐 수 있는지를 결정하고; 탐색 정책 π 는 독립적으로 과학적으로 발견 가능한 것을 결정한다—루프가 S 의 진정으로 미탐색 영역에 도달하는지 아니면 이미 착취된 전선에 머무는지. 표는 이 두 축 중 V 차원을 포착하며, π 차원은 조사된 모든 도메인에서 균일하게 미발달되어 있고 재료과학만 부분적 예외이다.