

AI 과학자 시스템의 형식화: 구성요소 프레임워크와 이론적 분석

신재솔 (Jaesol Shin)
WeDataLab
ysys143@gmail.com
<https://github.com/ysys143>

Abstract

기존 서베이는 AI 과학자 시스템을 capability와 workflow stage로 조직한다. 본 논문은 구성요소 interface, 평가 event, versioned artifact, routed edge, memory와 policy를 기록하기 위한 비망라적이고 출처 추적 가능한 진단 schema-어휘로 Servo (S, G, E, V, M, π)를 제안한다. 여섯 구성요소 core는 탐색 공간, 가설 생성기, 실험 실행기, 검증기, 메모리, 탐색 정책이며, 환경 관측법칙 O_{env} , artifact 상태 A , 선택적 artifact 합성·수정 interface W_A 는 추가 core 구성요소가 아니라 명시적 경계 객체다. 이 schema를 다섯 lineage의 versioned case 여섯 개와 선정·동결된 domain anchor 일곱 개에 적용한다. 하나의 폐쇄 label 대신 네 개의 보수적인 집합값 predicate를 사용하며, 각 status에는 동일 case-version-configuration-task regime 안의 출처 추적 가능한 witness가 필요하다. 사례와 anchor는 어휘의 적용을 예시할 뿐 대표 표본, prevalence 추정, 인과 검정 또는 다른 framework 대비 Servo의 우월성 입증은 아니다. 세 open problem도 전향적 설계 질문으로만 제시한다.

1 서론

AI 과학자 시스템은 급속도로 증가했다 [Boiko et al., 2023, Lu et al., 2024, 2026, Schmidgall et al., 2025, Feng et al., 2026, Liu et al., 2026]. Capability-stage 기반 서베이는 공유 조직틀을 제공하지만 [Wei et al., 2025, Tie et al., 2025], 분석 목적마다 시스템 경계가 달라진다. 본 논문의 질문은 더 좁다. 어느 평가 event가 어느 후속 행동에 연결되는가? 그 연결은 어느 artifact version을 통과하는가? 제한된 보고 configuration 안에서 어떤 feedback이 확립되는가? 신규성 평가나 정보추구 실험 정책에는 어떤 증거가 필요한가?

Servo¹은 POMDP와 베이지 실험 설계의 일부 용어로 조직된다. 다섯 lineage의 versioned case 여섯 개에 schema를 적용하고, 선정된 출처 anchor 일곱 개를 별도로 기술한다. 기여는 명시적 contract와 출처 추적 가능한 적용이지 완전한 ontology, 인과이론, 모집단 taxonomy 또는 성능 순위가 아니다.

범위. Servo는 비망라적 시스템 수준 진단 schema다. 각 case는 case, lineage, version, configuration, task-regime identifier로 식별되는 제한된 task regime 안의 versioned

¹서보메커니즘 비유는 feedback path 추적을 동기화할 뿐, 기록된 모든 path가 신뢰 가능하거나 인식론적·자율적·과학적으로 성공적임을 뜻하지 않는다.

system configuration이다. 포함은 실행·평가·artifact·routing·policy·권한·fidelity의 출처 추적 가능한 변이를 기록하기 위한 것이며, 사례가 AI 과학자 시스템을 망라하거나 대표한다는 뜻이 아니다. 여섯 구성요소 label과 세 전향적 설계 질문은 유지되며, 현재 interface와 operationalization은 versioned artifact, typed event·edge와 predicate별 witness를 포함한다.

2 배경

Kaelbling et al. [1998]에서 정책과 믿음 상태의 조직화 개념을 빌리지만 완전한 POMDP를 명세하지 않는다. 프레임워크의 S 는 세계 상태공간 $\mathcal{X}$ 와 다르고 b_t 는 제한된 출처가 실제 믿음 또는 posterior를 정의할 때만 사용된다. 사후 집중은 Servo의 네 closure predicate 중 어느 것도 아니며 어떤 predicate status도 신뢰 가능한 과학 성과를 정의하지 않는다. 수용 게이트가 “진리”를 추적한다는 단일 trustworthy-closure 변수도 정의하지 않는다. 속성 q 의 결과 연구는 외부 endpoint Y_q 를 사전 고정하고 시스템의 q -gate와 독립적으로 측정해야 한다. BED [Chaloner and Verdinelli, 1995, Rainforth et al., 2024]는 π 에 대한 하나의 규범적 정보 기준으로 EIG 최대화를 제시한다:

$$d^* = \arg \max_{d \in \mathcal{D}} \text{EIG}(d) = \arg \max_d \mathbb{E}[H(\theta) - H(\theta \mid y, d)] \quad (1)$$

여기서 $H(\theta)$ 는 매개변수 θ 에 대한 사전 엔트로피이고, $H(\theta \mid y, d)$ 는 d 하에서 y 를 관측한 후의 기대 사후 엔트로피이다. EIG는 변분 방법 [Foster et al., 2019], 분할 상환 정책 [Foster et al., 2021], 강화학습 [Blau et al., 2022]으로 근사할 수 있다. Robot Scientist [King et al., 2004]와 GNoME [Merchant et al., 2023]은 도메인 특화 능동학습 정책을 제시하지만, 여기서 사용한 제한된 LLM case 출처는 EIG 목적을 기술하지 않는다.

3 관련 연구

AI 과학자 시스템과 직접 비교 서베이. Wei et al. [2025]와 Tie et al. [2025]는 capability, workflow, 방법론 stage와 abstraction layer로 시스템을 비교한다. Servo는 versioned case identity, event, artifact, route와 predicate witness를 전면화한다. 이는 분석단위의 차이이지 Servo가 더 완전하거나 유용하다는 증거가 아니다.

자율 과학 프레임워크. Robot Scientist [Sparkes et al., 2010], InternAgent(구 NovelSeek) [InternAgent Team, Shanghai Artificial Intelligence Laboratory, 2025], Co-Scientist [Gottweis et al., 2026] 등 자동 feedback architecture는 Servo보다 앞선다. Servo는 최초의 통합 framework가 아니라 관측 생성, 평가 event, artifact, routed edge와 수용을 분리하는 어휘다. 진단적 가치는 예시될 뿐 다른 framework에 대해 독립 검증되지 않았다.

이론적 기반. POMDP [Kaelbling et al., 1998]와 BED [Chaloner and Verdinelli, 1995, Rainforth et al., 2024]는 고전적이다. Servo는 완전한 POMDP나 BED의 선취권을 주장하지 않고 용어만 빌린다. 이 contract는 validation target, evidence, evaluator, decision role, artifact state와 routed edge를 기록하며 이를 reliability hierarchy로 취급하지 않는다.

Provenance·workflow-run 표준. PROV-DM은 entity, activity, agent와 generation, usage, derivation, revision, association을 이미 정의한다 [Moreau and Missier, 2013]. Workflow Run RO-Crate도 workflow plan과 run, code, input/output artifact를 기록한다 [Workflow Run RO-Crate Community, 2023]. Servo는 이 기본

객체를 다시 정의하지 않는다. Artifact는 PROV entity, event는 activity 또는 run action, producer·consumer는 generation·usage, 인간·시스템 행위자는 agent·association에 대응한다. Servo의 추가 범위는 scientific target property, validator reliability record, typed epistemic·control route, bounded case identity, 구성요소별 authority와 predicate별 closure witness다. 이는 정식 PROV·RO-Crate conformance 주장이 아니라 loss-aware construct mapping이며, 정식 conformance에는 executable serializer와 해당 test가 추가로 필요하다.

과학의 형식 모델과 아티팩트 인프라. Taniguchi et al. [2025]는 공동체 수준 추론을 모델링하지만 Servo는 하나의 시스템 수준 case로 사회조직을 압축한다. Liu et al. [2026]은 artifact format, provenance와 verification을 전면화한다. Servo event-artifact schema는 이를 versioned A 상태와, 출처가 보고할 때 선택적 합성·수정 interface W_A 로 기록할 수 있다. 이는 경계 mapping이지 포섭이 아니다.

프레임워크	분석단위와 목적	전면화하는 해상도	의도적 생략 / 상충관계	출처
Servo	시스템 수준 발견 루프 비교	구성요소: 속성별 validator channel; 운영 피드백과 종결 평가	agent 통신과 사회조직을 압축하며 완전한 생성모형이 아님	본 연구
Wei et al.	capability-workflow-domain 통합	다섯 기반 capability와 네 동적 발견 stage	validator channel 운영/종결 routing은 분석단위가 아님	정체와 Wei et al. [2025]
Tie et al.	여섯 방법론 stage와 네 abstraction layer	50개 이상 시스템의 domain, task, architecture, capability coverage	memory, policy, 완전한 validator feedback path를 부호화하지 않음	Tie et al. [2025]

Table 1. AI 과학자 직접 서베이 framework와의 construct-level 비교. 성능 순위가 아니며 Servo의 제한된 증분 주장은 일부 channel/interface 구분을 명시적으로 만든다는 것이다. 최초의 통합 framework라는 주장이나 다른 틀이 이를 표현할 수 없다는 주장이 아니다.

POMDP, InternAgent, CPC-MS, ARA는 직접 survey taxonomy가 아니라 보완적 분석단위다. 각각 순차 의사결정, 구현된 multi-agent 조직, 공동체 인식 역학, artifact provenance와 replay를 전면화하며 Servo가 이들을 포괄하지 않는다 [Kaelbling et al., 1998, InternAgent Team, Shanghai Artificial Intelligence Laboratory, 2025, Taniguchi et al., 2025, Liu et al., 2026].

4 Servo 프레임워크

AI 과학자 시스템을 다음 구성요소를 가진 튜플 (S, G, E, V, M, π) 로 정의한다:

$$\text{Servo} = (S, G, E, V, M, \pi) \quad (2)$$

S : **탐색 공간 (Search Space)** 현재 표현된 후보 객체의 집합이다. S_t 는 고정되거나 명시적으로 확장될 수 있으며, 큰 고정집합을 오래 탐색하는 것만으로는 개방형이라 부르지 않는다.

$G : M \times S \rightarrow (C, \Delta S)$: **가설 생성기 (Hypothesis Generator)** 후보와 선택적 공간 확장을 함께 제안한다. $S_t^+ = \text{expand}(S_t, \Delta S_t)$ 이고 $C_t \subseteq S_t^+$ 로 둔다. 고정공간 탐색에서는 $\Delta S_t = \emptyset$ 이며 progressive widening이나 새 representation은 ΔS_t 에 기록한다.

$E \equiv E_{\text{exec}} : h \times d \times P \times f \rightarrow u$: **실험 실행기** 선택한 가설, 설계, 프로토콜, fidelity를 실행된 intervention 또는 계산 행동 u 로 바꾸는 시스템 통제 구성요소다. 코드 실행기, simulator, robot, protocol orchestrator일 수 있다. 자연이나 simulator의 확률적 반응은

executor 자체가 아니며, 보조적 환경·측정법칙 $O_{\text{env}}(\text{do} \mid x, u)$ 로 둔다. 여기서 x 는 Servo 구성요소가 아닌 환경 상태다. 따라서 $o \sim O_{\text{env}}(\cdot \mid x, E_{\text{exec}}(h, d, P, f))$ 이다. 이 법칙은 일곱 번째 Servo 구성요소도 architecture coding에서 추론하는 필드도 아니다. 통계모형이 이를 별도로 제공해야 belief update와 EIG를 계산할 수 있다.

$V = \{V_j : (z_j, A_v) \rightarrow r_j\}_{j \in \mathcal{J}}$: **검증 event** 단일 사후 호출이 아니라 맥락 의존 평가함수의 집합이다. A_v 는 event가 소비하는 모든 versioned artifact를 식별하며, 그 producer, version과 case boundary는 artifact record에서 해소돼야 한다. 맥락 입력 $z_j = (h, d, P, o, M, K_{\text{ext}}, \tau)$ 는 추가로 후보 주장·가설, 설계, 프로토콜, 관측, 내부 메모리, 외부 참조 corpus, 평가 시점 cutoff를 포함할 수 있다. 출력 r_j 는 실행 가능성·경험적 적합성·재현성·신규성·유의성·수용 여부의 속성별 벡터일 수 있다. 실행 검사는 (P, o) 만 사용할 수 있지만 field novelty는 (h, o) 를 시간 기준이 있는 외부 선행연구 (K_{ext}, τ) 와 비교해야 한다. 검증기는 더할 수 있는 계층이 아니라 별도 facet으로 코딩한다: 목표 속성(실행 가능성·경험적 적합성·신규성·유의성), 증거원(실행 trace·측정·재현·문헌·review), 평가 기반(program·통계모형·LLM·인간·hybrid), 의사결정 역할(진단·탐색 통제·수용), 외부 독립성(내부·공유·독립). 한 facet 안에서 복수 값이 가능하며 서로 다른 facet의 값을 성숙도처럼 더하지 않는다. Event 자체가 route를 만들지는 않는다. 별도로 입증된 edge가 r_j 를 $D_j \subseteq \{S, G, E, V, M, \pi, A, W_A, \text{external}\}$ 로 전달할 수 있다. Artifact revision은 특히 W_A 로 향하는 route와, 새 artifact version A_{v+1} 을 생성하는 artifact_revision edge로 표현한다. A_v 를 제자리에서 변경하는 것은 허용되는 지름길이 아니다.

M: 메모리 (Memory) (M_e, M_s, M_p)로 구성. M_e (일화)는 개별 기록 (h_i, o_i, r_i) 를 저장; M_s (의미)는 증류된 지식 패턴을 저장; M_p (절차)는 학습된 프로토콜을 저장. M 의 구조는 G 와 π 의 품질을 직접 결정한다.

$\pi : b \times M \times \mathcal{C} \times B \times R_{\text{pre}} \rightarrow a$: **탐색 정책 (Search Policy)** 후보, 설계, 프로토콜, fidelity로 이루어진 행동 $a = (h, d, P, f)$ 를 선택한다. B 는 잔여 예산이고 R_{pre} 는 행동 전 channel 신호다. 근시안적 BED 정책은 후보·가용 행동 구성을 고정하고 조건부 EIG를 최대화하는 행동 또는 그 설계 성분을 고른다. 이는 전역적으로 최적인 순차 정책이 아니다. 따라서 G 는 후보와 공간 확장을 생성하고 π 는 믿음 상태에서 행동을 선택한다 [Kaelbling et al., 1998].

이식 가능한 event-artifact graph. 제한된 case c 에 대해 Servo는 endpoint, versioned artifact, 평가 event와 방향 edge를 기록한다:

$$\mathcal{G}_c = (\mathcal{N}_c, \mathcal{A}_c, \mathcal{E}_c, \mathcal{R}_c). \quad (3)$$

$\mathcal{N}_c$ 는 $S, G, E, V, M, \pi, A, W_A$ 와 external을 포함하는 typed component 또는 경계 endpoint, $\mathcal{A}_c$ 는 producer와 version을 가진 artifact, $\mathcal{E}_c$ 는 평가 occurrence, $\mathcal{R}_c$ 는 observation, epistemic-update, feedback-control, artifact-revision 또는 external-only edge다. Event class마다 허용 actor component를, edge type마다 허용 source-destination component 쌍을 두며 package는 두 표현의 불일치를 거부한다. 인간·시스템·혼합·미보고 mediation은 별도 edge topology가 아니라 actor facet이다. Event와 reliability evaluation은 다른 record다. 평가 연구는 runtime event가 아니며 feedback edge로 사용할 수 없다. A 는 event가 소비·생성하는 artifact 상태이고, 선택적 W_A 는 출처가 보고한 artifact 합성·수정 interface다. 둘은 여섯 구성요소의 경계에 있으며 core tuple을 암묵적으로 확장하지

않는다. Artifact 수정 route는 W_A 와 새 version을 명시해야 한다. Terminal event에는 outgoing internal edge가 없다. Pre-action filter, 고정 schedule, append-only memory, formatting·copying, epistemic update 없는 retry, terminal assessment만으로는 closure witness가 되지 않는다.

집합값 폐쇄 기술. Servo는 하나의 yes/partial/full loop label을 부여하지 않는다. 각 case에 대해 실행 복구, 실험 적응, 산출물 수정, 발견 주기 피드백의 네 predicate 각각에 {established, not established, unknown, not applicable} 중 하나를 보고한다. 실행 복구는 runtime failure evidence, W_A 를 통한 artifact 수정과 후속 실행을, 실험 적응은 평가 evidence가 변경된 실험 행동을 제어하고 그 행동이 후속 실행되는 path를, artifact 수정은 successor version을, 발견 주기 피드백은 명시적 epistemic update와 그 사이의 epistemic action·새 실행·새 evidence를 요구한다. 동일 path는 각 contract를 독립적으로 충족할 때만 여러 predicate의 witness가 될 수 있다. 인간 개입은 이들 path에 붙는 별도의 actor facet이며 그 자체로 closure를 뜻하지 않는다.

Evidential status도 구분한다. Established는 positive witness가 있을 때만, unknown은 필수 event·edge·순서·artifact identity·source link가 누락되거나 모호할 때 사용한다. Not established는 명시적 반대 근거나 완전히 보고된 eligible trace가 필수 transition을 충족하지 못한 경우로 제한하며, source silence만으로는 unknown이다. Not applicable은 사전 정의된 범위 밖 이유가 필요하다. Graph pattern, mismatch rule과 반례는 predicate_contract.md에 규정하고 validator가 기계 판독 가능한 부분을 강제한다.

인간 개입의 기존 단일 연속값 $H \in [0, 1]$ 은 폐기한다. 대신 구성요소별 인간 권한을

$$H = (H_S, H_G, H_E, H_V, H_M, H_\pi)$$

로 기록한다. H_S 는 초기 문제· S_0 설정과 이후 공간 확장 권한을 G 의 후보 생성 권한과 구분한다. 나머지 성분은 인간이 해당 기능을 개시·조언·승인·실행하거나 최종 결정권을 유지하는지를 기술한다. 이는 수치나 순서척도가 아니며, 표 2은 인간 권한 또는 참여가 보고된 구성요소를 표시한다 [Parasuraman et al., 2000].

다중 facet 검증기 기술. 과거의 V_{syntax} , V_{semantic} , $V_{\text{empirical}}$, V_{human} , V_{formal} 표기는 목표 속성·증거원·평가 기반·의사결정 역할을 혼합했으며 상호배타적 계층도 신뢰도 순서도 아니었다. Gate 신뢰성 증거는 runtime event와 별도로 기록하고 confidence-outcome 대응을 실제 측정한 경우에만 확률적 calibration이라 부른다. Balanced accuracy, false-positive rate, 평균 점수 편향, coder agreement는 calibration이 아니다. 폐기된 이전 필드는 재구성 자료일 뿐 현재 schema의 의미 입력이 아니다.

4.1 관측·보상·신규성 채널의 분석적 분리

서로 혼동하기 쉬운 세 대상을 분리한다: 베이즈 갱신에 쓰이는 관측 가능도 $p(o \mid \theta, d)$, 보상 또는 수용 신호로 쓰이는 맥락 의존 검증기 $V(z)$, 그리고 신규성·유의성에 대한 증거를 전달하는 추가 채널이다. 관찰 2는 Berk의 고정 i.i.d. 결과를 적용하기 위해 다른 맥락을 고정한 제한적 특수사례 $V(o)$ 만 다루며 신규성 또는 수용의 일반 모형이 아니다. 아래 관찰은 고정된 이상화 설정에 표준 결과를 적용한 것이고 적응적 실험 설계나 개방형 과학에 대한 새로운 일반 정리가 아니다.

관찰 1: 사후 일치성은 관측 채널에 속한다. 참 분포가 p_{θ^*} 인 지배된 고정 i.i.d. 모형 $\{p_\theta : \theta \in \Theta\}$ 에서는 모형이 참값을 식별하고, 사전 분포가 참값의 모든 쿨백-라이블러 근방에 양의 질량을

주며, 적절한 일치 검정이 참값과 그 근방의 여집합을 분리하고, 해당 일치성 정리가 요구하는 정책 조건이 충족될 때 사후 일치성을 얻을 수 있다 [Ghosal and van der Vaart, 2017]. 콤팩트성, 식별성, 위상적 의미의 사전 받침만으로 이 조건들을 대신할 수 없다. 따라서 인용된 결과만으로 AI 과학자의 적응적·비정상 설계 수열에 대한 일치성이 성립하지 않으며, 그 체제에는 별도의 정리가 필요하다.

식 1은 일단계 정보 목적을 정의한다. 이를 최대화하는 규칙은 정의상 그 일단계 목적에 대해 근시안적으로 최적이지만, 순차적 과학 정책의 전역 최적성을 뜻하지 않는다. $\mathcal{H}_{t-1}$ 가 과거 설계와 관측을 포함하고 d_t 가 이 이력에 대해 가측이라 하며, $\text{EIG}_t = I(\theta; O_t \mid \mathcal{H}_{t-1}, d_t)$ 로 정의하자. 사후 집중에 이 일단계 EIG 합의 발산이 필요한 것은 아니다. 예를 들어 θ 가 유한 엔트로피를 갖는 이산 변수이면 조건부 정보의 연쇄법칙에 따라

$$\sum_{t \geq 1} \mathbb{E}[\text{EIG}_t] = I(\theta; \mathcal{H}_\infty) \leq H(\theta), \quad (4)$$

이므로 유한한 누적 기대 정보와 사후 집중은 양립한다. V 가 가능도 밖에 머무르면 이 고정 모형 일치성 명제에 직접 관여하지 않지만, 정책이 V 를 사용하면 미래 설계와 관측을 간접적으로 바꿀 수 있다.

관찰 2: 결합된 검증기는 정규화된 가능도를 통해서만 의사참 표적을 바꾼다. 고정 설계 d 에서 다음 갱신을 사용한다고 하자.

$$q_{\theta,d}(o) = \frac{p(o \mid \theta, d) \exp\{\beta V(o)\}}{Z_\theta(d)}, \quad (5)$$

$$Z_\theta(d) = \int p(u \mid \theta, d) \exp\{\beta V(u)\} du < \infty.$$

고정 i.i.d. 자료생성 분포를 F 라 하자. Berk 유형의 오설정 결과가 요구하는 정책성, 적분 가능성, 분리 및 사전 질량 조건 아래에서 사후 질량은 자동으로 하나의 점이 아니라 다음 최소화 집합을 향한다.

$$\Theta^\dagger = \arg \min_{\theta \in \Theta} \text{KL}(F \parallel q_{\theta,d}) \quad (6)$$

이 집합이 한 원소일 때에만 그 원소를 $\theta^\dagger$ 라 쓴다 [Berk, 1966]. 검증기 유도 표류는 이 최소화 집합이 원래 가능도 $p(\cdot \mid \theta, d)$ 아래의 사영과 달라지는 경우를 뜻한다. V 에 명시적인 θ 인자가 없어도 결과 의존성 때문에 정규화 상수 $Z_\theta(d)$ 가 달라질 수 있지만, V 의 비상수성만으로 표적 변화가 보장되지는 않는다. V 에 더한 상수는 분자와 정규화 상수 사이에서 상쇄되고, $\beta = 0$ 이면 $q_{\theta,d} = p(\cdot \mid \theta, d)$ 이다. 정책에서만 쓰인 검증기가 미래 설계 선택을 바꾸는 효과는 적응적 설계 문제이지 Berk [1966]의 고정 i.i.d. 결론이 아니다.

관찰 3: 모든 가용 채널에 보이지 않는 신규성은 식별되지 않는다. 잠재 상태를 $\theta = (\theta_{\text{nov}}, \psi)$ 로 쓰고, 사전분포가 $\Pi(d\theta_{\text{nov}}, d\psi) = \Pi_{\text{nov}}(d\theta_{\text{nov}})\Pi_\psi(d\psi)$ 로 인수분해된다고 하자. 모든 관측 채널의 결합 가능도가 ψ 에는 의존하지만 θ_{nov} 와 무관하면, θ_{nov} 의 사후 주변분포는 모든 자료에서 Π_{nov} 와 같다. 모든 가능도 관련 잠재 성분으로부터의 이 완전한 인수분해는 필수적이다. 이미 식별된 성분과의 독립만으로는 사전적으로 상관된 방해변수를 통한 간접 갱신을 배제하지 못한다. 따라서 이 채널들만으로는 신규성 성분을 일치되게 식별할 수 없다. 식별에는 정보를 담은 추가 채널이 필요하지만, 이 전제로부터 그 채널이 원리상 반드시 인간이어야 한다는 결론은 나오지

ID	계보	시스템/버전	구성	과제 범위
C01	coscientist	Coscientist (2023년 논문)	보고된 시연	화학 과제 6개
C02	ai_scientist	AI Scientist 2024 (2024년 논문)	보고된 기본 설정	계산 실험 최대 5회
C03	ai_scientist	AI Scientist 2026 (2026년 Nature)	템플릿 없는 트리	계산 트리 탐색
C04	agent_laboratory	Agent Laboratory (2025년 논문)	자율 모드	인간 제공 ML 아이디어
C05	robot_scientist	Robot Scientist (2010년 Adam 리뷰)	Adam 효모	효모 기능유전체학
C06	novelseek	InternAgent(구 NovelSeek) (2025년 InternAgent)	보고된 다중 에이전트	계산 과제 12개

Table 2. 다섯 lineage의 versioned case 여섯 개. ID, version, configuration과 task regime은 Servo 정본 record에서 생성된다.

ID	실행 복구	실험 적응	산출물 수정	발견 주기 피드백
C01	{확립}	{불명}	{확립}	{불명}
C02	{불명}	{확립}	{불명}	{미확립}
C03	{불명}	{확립}	{불명}	{불명}
C04	{확립}	{불명}	{확립}	{미확립}
C05	{불명}	{확립}	{해당 없음}	{확립}
C06	{확립}	{확립}	{확립}	{미확립}

Table 3. 집합값 closure-predicate status. 각 열은 하나의 closure 척도의 level이 아니라 독립 predicate이며, 확립 값마다 동일 case 안의 명시적 witness가 필요하다.

않는다. 서버이가 지지하는 더 좁은 경험적 진술은 조사된 시스템들의 신규성·유의성 판단이 인간 매개이거나 검증된 자동 게이트를 갖추지 못했다는 것이다.

이 관찰들은 관측, 보상 검증, 신규성 판단을 분리하는 본 논문의 진단적 어휘를 뒷받침한다. 과거의 단일 V -완결성 순서형과 gate 신뢰성-trustworthy closure 연관 가설은 철회한다. 향후 연구가 과학적 성과를 다루려면 속성별 gate와 독립적인 외부 결과를 새로 정의하고 측정해야 하며, 현재 유지되는 closure 연관 가설은 없다.

5 핵심 AI 과학자 시스템 분석

동결된 적용은 다섯 lineage의 versioned case 여섯 개다: Coscientist, 한 lineage의 두 version인 AI Scientist 2024와 AI Scientist 2026, Agent Laboratory, Robot Scientist, InternAgent(구 NovelSeek). 각 case는 보고된 configuration과 task regime으로 제한된다. 이 record들은 모집단의 “핵심” 대표가 아니라 선정된 출처 추적 가능 사례다. S, G, E, V, M, π , 경계 객체 O_{env}, A, W_A , 인간 권한, endpoint, event, artifact, routed edge, reliability evaluation과 Servo event-artifact contract를 충족하는 closure witness를 기록한다.

각 cell은 `servo2_closure_statuses.csv`의 `case_id`와 `predicate`로 식별된다. Established cell은 순서화된 `witness_ids`를 지목하며, 각 witness는 release package의 event, edge, endpoint, artifact, evidence, source location과 source hash record로 해소된다.

Event graph는 bare loop label이 지우는 차이를 보존한다. AI Scientist lineage에서는 pre-action 문헌 filter, runtime experiment 또는 tree 평가, manuscript assessment와 external review가 서로 다른 artifact-목적지를 가진 별도 event다 [Lu et al., 2024, 2026].

Coscientist와 Agent Laboratory는 실행 또는 artifact-revision path를 보고하지만 각 closure predicate는 동일 case 안의 순서화 witness가 있을 때만 판정한다 [Boiko et al., 2023, Schmidgall et al., 2025]. Robot Scientist는 제한된 yeast functional-genomics regime 안에서 physical assay와 model-update cycle을 보고한다 [King et al., 2004, Sparkes et al., 2010]. InternAgent는 multi-agent assessment, debugging과 evolution을 보고하지만 Servo는 agent 간 조직을 의도적으로 압축한다 [InternAgent Team, Shanghai Artificial Intelligence Laboratory, 2025]. 인간의 범위 설정, manual execution, terminal authority와 external assessment는 scalar autonomy나 closure 값으로 변환하지 않고 별도로 기록한다.

규범적 데이터 모델은 `servo_schema.yaml`이 지목하는 case, endpoint, artifact, event, edge, reliability-evaluation, closure-witness, closure-status, domain-anchor와 selection-ledger record로 구성된다. 동결된 42세션·3벤더 다중 코더 audit은 폐기된 record-level rubric을 사용해 현재 event, artifact, edge 또는 predicate 단위를 코딩하지 않았으며 역사적 개발 audit 자료로만 남는다.

5.1 프레임워크 대조 독해

첫째, AI Scientist(Nature 2026)를 하나의 loop label로 부르면 stage/tree evaluator, manuscript reviewer, 수동 제출 뒤 workshop review의 차이가 사라진다. 둘째, Agent Laboratory의 내부 실행·artifact-revision path는 paper-quality assessment와 유지된 인간 권한과 다르다. 셋째, InternAgent의 native multi-agent architecture는 agent 역할과 communication을 Servo의 system-level case record보다 더 직접 표현한다 [InternAgent Team, Shanghai Artificial Intelligence Laboratory, 2025]. 이는 전면화하는 분석단위의 차이 지 성능·우월성 비교가 아니다.

Robot Scientist는 자동적인 진단 가치 주장에 대한 부정 사례다. 원 출처가 이미 가설, assay, update와 선택 sequence를 드러낸다 [King et al., 2004, Sparkes et al., 2010]. Servo는 일관되게 검증되는 record format과 문서화된 mapping target을 제공하지만 숨은 mechanism을 새로 발견한 것은 아니다. 사례들은 schema가 무엇을 전면화하는지만 보여준다.

5.2 아티팩트 인프라: 에이전트 네이티브 연구 아티팩트

Liu et al. [2026]은 AI 과학자 루프의 출력과 독립 검증이라는 상호 보완적 문제를 다룬다. ARA는 `/logic`, `/src`, `/trace`, `/evidence`의 네 부분을 사용한다. 최종 Servo facet으로 쓰면 Seal은 결정적 검사, 자동 Rigor Auditor(82.6% 탐지율), sandbox 실행을 증거로 schema compliance, 논증 엄격성, 재현성을 평가하고, 유의성과 신규성은 인간 판단에 남긴다 [Liu et al., 2026]. 출판 논문의 재현 요건 중 45.4%만 완전히 명시되고 확장 비용의 90.2%가 실패 탐색에 쓰인다는 결과가 이를 동기화한다. `/trace`는 M_e 와 M_s 를 외부화하지만 보존된 trace는 후속 agent를 가속하면서도 이전 경로에 고착시킬 수 있다.

6 도메인 분석

표 4은 선정·동결된 출처 anchor 일곱 개를 나열한다. 각 행은 하나의 이름 붙은 시스템과 하나의 제한된 1차 출처다. 행을 domain-level case, sampling frame, prevalence 주장 또는 cross-domain outcome 비교로 합치지 않는다.

Anchor 행은 출처 국소 기술만 지지한다. 어떤 pattern이 domain 전반에 성립하는지, 특정 validator 유형이 outcome을 일으키는지, 일곱 anchor가 관련 design space를 포괄하는지를

ID	시스템/분야	분석 대상	평가기/근거	의사결정 역할	충실도 경계
DA01	FunSearch / 형식수학	프로그램 과제 성능	품질과 실행 가능 평가기	순위화와 탐색 제어	계산 오라클
DA02	AI Feynman / 물리학	데이터에 대한 기호 적합	기호회귀 알고리즘	모형 탐색과 적합	계산 데이터 적합
DA03	ChemCrow / 화학	과제 성능과 합성	도구·실행·평가	계획·실행·평가	계산·물리 혼합
DA04	GNoME / 재료과학	상 안정성과 에너지	그래프 신경망과 DFT	필터링과 능동학습 갱신	대리모형; 실험은 별도
DA05	BioPlanner / 생물학	프로토콜 실행 가능성	계획과 생성기·평가기·실험실	진단과 외부 실행	프로토콜에서 물리 실험실로
DA06	Manning 자동화 사회과학 / 사회과학	인과 가설과 모의 효과	인과모형과 에이전트	설계와 모형 갱신	모의 피험자
DA07	AutoML-Zero / 컴퓨터과학	진화 알고리즘의 벤치마크 성능	실행 가능 벤치마크	선택과 진화 갱신	계산 벤치마크

Table 4. 선정·동결된 출처 anchor 일곱 개. 이 행은 이름 붙은 경계에서 어휘를 구체화하는 방법만 보여주며 대표 domain 표본이나 공통 outcome 척도가 아니다.

확립하지 않는다. DFT는 물리 oracle이 아니라 물리 에너지 근사이며 예측 화합물에는 여전히 합성·특성화가 필요하다 [Cheetham and Seshadri, 2024].

7 미해결 문제

선정된 case와 anchor 출처는 세 가지 전향적 설계 질문을 제기한다. 이 자료는 유병도나 분야 전체의 부재를 확립하지 않으며, 제안된 평가는 여기서 수행하지 않는다.

7.1 검증된 자동 신규성 게이트의 부재

여기서 사용한 제한된 출처는 독립적으로 검증된 자동 신규성 게이트를 보고하지 않는다. 이는 모든 자동 신규성 점수가 신뢰 불가능하다거나 다른 시스템에도 그러한 증거가 없다는 판정이 아니라, 이 출처 범위에 한정된 증거 진술이다. 인용된 실패들은 인접하지만 별개의 속성을 측정한다: Agent Laboratory의 +2.3점은 전체 논문 품질 편향이고 [Schmidgall et al., 2025], AI Scientist의 환각 표와 에르되시 해법 13/200은 진실성·정확성 문제이며, ARA는 구조적 위반을 측정하고 [Liu et al., 2026], 45인 전문가 연구는 리뷰 품질과 증첩을 평가한다 [Kim et al., 2026]. 블랙박스 역공학 실패 [Geng et al., 2025]와 라이덴 선언의 증명 오류 경고 [Alper et al., 2026]도 novelty 판별의 민감도·특이도를 측정하지 않는다. 이 사례들은 자동 과학 평가 일반에 대한 주의 근거일 뿐이며 신규성·정확성·유의성·종합 리뷰 품질은 별도 endpoint로 유지한다.

여러 시스템은 생성과 review·reflection·ranking을 기능적으로 분리하지만, 이는 통계적·조직적 독립성을 뜻하지 않는다. 충족되지 않은 더 좁은 조건은 분리된 channel이 field novelty를 판별한다는 독립적·오염 통제 근거다.

전향적 검증 설계 요건: 다음은 충분조건이 아니라 필요한 설계 요건이다. 사전등록에는 target population, 시간 cutoff, domain strata, novelty prevalence 또는 sampling scheme, 주 판별 endpoint(민감도·특이도 또는 AUC), 최소 의미 성능, 목표 신뢰구간 폭을 명시한다. 전향적 power·precision 계산으로 도메인별 item 수와 rater 수를 정하며, 3개 domain과 5명 expert는 다양성 하한일 뿐 표본크기 계산을 대체하지 않는다. 전문가 독립 라벨, 불확실성을 포함한 human-human agreement, 명시적 prior-art search에 기반한 held-out adjudication을 사용하고 novelty·significance·correctness를 분리한다. 후속 우선권 결과의 follow-

up 기간, censoring, 판정 규칙도 사전등록한다. 소규모 패널과의 높은 일치나 출판/보류 구분은 초기 결과일 뿐이다 [Liu et al., 2025].

7.2 π 의 BED-실제 격차

식 1은 일단계 정보 기준을 명시하지만, 여기서 사용한 제한된 LLM case 출처는 그 정책이 EIG 또는 순차 정보 목적을 최적화한다고 기술하지 않는다. 이는 분야 전체의 부재 주장이 아니라 이 출처 범위에서 관찰된 채택·통합의 공백이다. 현대 BED는 변분 EIG 추정과 분할상환 정책을 일반적으로 사용하므로 [Foster et al., 2019, 2021], 관측으로 갱신되는 명시적 확률 대리모델도 유효한 구현 경로다. GNoME [Merchant et al., 2023]은 추적 가능한 GNN 모델의 심층 앙상블 불확실성을 사용하는 도메인 특화 근사이며, BED-LLM [Choudhury et al., 2026]은 대화형 질의에서 LLM 예측분포로 EIG 목적을 구성한다. 여기서 남는 질문은 직접적인 텍스트 posterior의 부재가 아니라, 보고된 $G-\pi$ 행동 인터페이스와 과학적 증거 경로에 이러한 목적을 통합하는 일이다.

전향적 성공 기준: 관측으로 갱신되는 확률모형—정확·변분·앙상블 또는 문서화된 다른 대리모형—을 유지하고, 명시적 예산 아래 검증된 EIG 또는 순차 정보 목적으로 행동 a_t 를 선택하는 배포 시스템은 이 서베이 격차를 좁힌다. 발견 관련 효용과 정보 효용을 대응되는 휴리스틱 정책과 비교해야 한다. 개방형 자연어·프로그램 가설을 직접 베이스 표상하는 문제는 별도의 더 강한 표상 과제이며 BED 통합의 필수조건이 아니다.

시스템은 명시적 확률 대리모형이나 변분·분할상환 EIG 추정을 사용할 수 있다 [Foster et al., 2019, 2021]. 개방형 S 에서 어려운 점은 그 목적이 의미를 갖는 표상을 정의하고 갱신하는 것이다. 이미 표상된 가설을 선택하는 BED와 새로운 표상이 어떻게 발생하는가의 생성 문제는 구별해야 한다 [Yanai and Lercher, 2019].

7.3 다중 충실도 통합 격차

Test-time compute는 가설 생성을 빠르고 저렴하게 만들었지만 실험 실행 E 는 물리적으로 속도 제한이 있다. 그러나 저비용 근사와 고비용 목표 평가를 고르는 원칙적 기준 자체는 다중 충실도 베이스 최적화에 이미 존재한다. 연속 충실도 모형은 근사 비용과 목표 정보를 교환하고 [Kandasamy et al., 2017], 비용 민감 상호정보 획득함수는 simulation과 실제 평가 사이의 정보원을 선택한다 [Song et al., 2019]. 여기서의 격차는 기준의 이론적 부재가 아니라, 충실도 변화가 프로토콜·결과 의미·물리적 실행 가능성까지 바꾸는 개방형 AI 과학자 workflow에 이 기준을 통합·검증하지 못한 점이다.

선정 anchor는 여러 proxy-to-physical 경계를 드러낸다. GNoME는 DFT로 38만 개의 안정 구조를 예측했으며 [Merchant et al., 2023], 736개는 ICSD에 독립적으로 존재하거나 이후 추가된 구조와 일치하고 그중 184개는 프로젝트 시작 뒤 추가됐다. 이는 시스템이 촉발한 합성이 아니라 다른 연구자의 동시기 기록이다. ChemCrow는 wet-lab 실험을 보고하지만 물리 특성화는 protocol별 경계로 남는다 [Bran et al., 2024, Gromski et al., 2019]. BioPlanner의 protocol artifact만으로 biological-validity feedback witness가 성립하지 않는다 [O'Donoghue et al., 2023]. 이 anchor들은 multi-fidelity 통합 문제를 동기화하지만 그 prevalence를 확립하지 않는다.

자율 실험실은 이 통합 격차와 직접 관련된다. A-Lab [Szymanski et al., 2023]은 계산 스크리닝과 로봇 합성을 결합하고, ORGANA [Darvish et al., 2024]와 AutoLabs [Panapitiya et al., 2025]는 습식 실험 또는 하드웨어용 프로토콜을 자동화한다. 이들은 실험 역량의 인접 사례로 인용되며, 이 절에서 그 보고들을 비용·불확실성을 반영한 MFBO 정책의 포괄적 감사

대상으로 삼지는 않는다. 하드웨어 자동화와 충실도 선택은 별개의 동시에 상호 보완적인 공학 문제다.

Test-time scaling은 이 격차를 해소하지 못한다. 더 많은 추론 단계는 DFT 벽시계 시간, 습식 실험실 처리 시간, 합성 지연을 줄일 수 없다; 이는 E 에 대한 물리적 제약이지 계산적 제약이 아니다. 이 격차는 기존 결과 캐싱이나 검색 메커니즘으로도 이미 해결되지 않는다: 이들은 과거 실험 결과를 축적하지만 더 높은 충실도 측정에 언제 투자할지를 결정하지는 않는다. 누락된 구성요소는 계산적 증거가 축적됨에 따라 그 증거가 물리적 검증 비용을 정당화하기에 충분한지를 결정하는 기준이다—그리고 충분하지 않다면, 어떤 추가적인 계산 실험이 가장 효율적으로 격차를 좁힐지를 결정하는 기준이다.

이 문제는 Op1·Op2와 구조적으로 구별된다. 어떤 V 든 입력으로 받은 fidelity의 증거만 평가할 수 있고 EIG 기반 π 도 현재 표상된 fidelity 사이에서만 선택한다. E 승격 기준이 없으면 더 높은 fidelity의 물리 증거로 이어지는 route가 확립되지 않을 수 있다. 세 문제는 진단적으로 상호작용하지만 보편적 필요조건이나 단일 closure 상태를 정의하지 않는다.

전향적 성공 기준: 비용과 교차 충실도 불확실성을 포함한 문서화된 다중 충실도 획득 규칙을 구현하고, 사전등록 평가에서 고정 충실도·고정 승격 기준선보다 단위 물리 비용당 검증된 발견을 더 많이 산출하면 통합 격차가 줄었다는 증거가 된다. 이는 원래 기준의 발명이 아니라 AI 과학자 workflow에서의 채택과 보정을 시험한다.

핵심 설계 질문은 두 가지다: 계산 증거가 얼마나 확신적이어야 물리 승격이 정당화되는가, 그리고 오라클 보정 오차(예: DFT 근사치)를 임계값에 어떻게 반영할 것인가? 선정된 case와 anchor 출처는 이 두 질문을 함께 다루는 정책의 존재 여부를 포괄적으로 판정하는 표본이 아니다. 세 미해결 문제는 가능한 순차 의존을 드러낸다: 각 fidelity의 V 신호 $\rightarrow$ 가설 우선순위를 정하는 $\pi \rightarrow$ 계산 증거를 물리 검증으로 승격하는 E 기준. 이는 보편적 필요조건이나 causal model이 아니라 prospective design question을 배열하는 진단 관계다.

8 논의

검증기 설계의 진단적 어휘. 과거의 gate-reliability/“trustworthy closure” 연관은 단순 미검정이 아니라 정의상 순환적이므로 철회한다. 프레임워크는 대신 어느 channel이 언제 작동하고 어디로 전달되는지, 어떤 속성을 평가하는지, 어떤 편향·보정 증거가 있는지, fidelity와 외부 독립성이 어떠한지를 묻는다. 향후 결과 분석은 gate와 독립적인 외부 endpoint Y_q 를 사용해야 한다.

인간 감독. 범주형 권한 벡터는 인간이 어느 기능을 개시·조언·승인·실행하거나 최종 통제하는지를 드러내며 최소화할 단일 수치가 아니다. 조사된 workflow에는 신규성·유의성 평가와 policy에서 명시적 인간 권한이 포함되지만, 이는 인간 채널의 원리적 불가대체성을 뜻하지 않는다 [Parasuraman et al., 2000].

집합적 AI 공동 과학자를 향하여. InternAgent를 포함한 일부 분석 시스템은 명시적으로 multi-agent다 [InternAgent Team, Shanghai Artificial Intelligence Laboratory, 2025]. 그러나 본 논문은 각 구현을 하나의 시스템 수준 (S, G, E, V, M, π) tuple로 압축하여 agent별 역할·통신·불일치·권한을 모델링하지 않는다. 따라서 필요한 확장은 multi-agent 시스템의 도입이 아니라 시스템 수준 추상화를 agent graph, shared-memory process, collective validator 또는 Dec-POMDP형 모델로 세분화하는 것이다. CPC-MS [Taniguchi et al., 2025]와 ARA [Liu et al., 2026]는 공유 인식 상태의 출발점이 될 수 있다. 이러한 확장은 AI reviewer의 높은 상호 중첩 [Kim et al., 2026]을 고려해 인식론적 다양성도 보존해야 한다 [Zollman, 2010].

한계. Servo은 비망라적이며 agent-level 사회조직을 추상화한다 [Taniguchi et al., 2025]. 여섯 case와 일곱 anchor는 선정된 출처 추적 record이지 대표성이나 모집단 타당성을 가진 표본이 아니다. Predicate status는 제한된 case와 witness에만 해당하며 과학 성과의 질을 함의하지 않는다. Servo는 누락된 route, 비용, fidelity transition 또는 artifact에 대한 인과모형이나 생성법칙을 제공하지 않는다. 동결된 42세션·3벤더 다중 코더 audit은 현재 event-artifact contract보다 앞선 역사적 개발 audit일 뿐이며, 그 agreement coefficient는 현재 case annotation의 재현성, source entailment, 구성타당성, 인간 신뢰도, 실제 효용 또는 비교 우월성을 입증하지 않는다.

9 결론

본 논문은 Servo (S, G, E, V, M, π)를 비망라적이고 출처 추적 가능한 event-and-evidence schema로 제시했다. 다섯 lineage의 versioned case 여섯 개와 동결 anchor 일곱 개는 평가 event, artifact version, route, 권한과 네 보수적 closure predicate의 기록법을 예시한다. Prevalence, 인과, 비교 우월성 또는 과학 성과 효과를 확립하지 않는다.

References

- J. Alper, M. Barany, A. Chavarri Villarello, S. Dahmen, W. Dean, K. Ganapathy, M. Harris, D. Holmes, M. Jamnik, S. Kelk, B. Kra, U. Martin, B. Naskręcki, R. Ochigame, J. Portegies, and J. Schmitt. Leiden declaration on artificial intelligence and mathematics. <https://leidendeclaration.ai>, June 2026.
- R. H. Berk. Limiting behavior of posterior distributions when the model is incorrect. *The Annals of Mathematical Statistics*, 37(1):51–58, 1966.
- T. Blau, E. V. Bonilla, I. Chades, and A. Dezfouli. Optimizing sequential experimental design with deep reinforcement learning. In *International Conference on Machine Learning*, 2022. arXiv:2202.00821.
- D. A. Boiko, R. MacKnight, B. Kline, and G. Gomes. Autonomous chemical research with large language models. *Nature*, 624:570–578, 2023. doi: 10.1038/s41586-023-06792-0.
- A. M. Bran, S. Cox, O. Schilter, C. Baldassari, A. D. White, and P. Schwaller. ChemCrow: Augmenting large-language models with chemistry tools. *Nature Machine Intelligence*, 2024. arXiv:2304.05376.
- K. Chaloner and I. Verdinelli. Bayesian experimental design: A review. *Statistical Science*, 10(3):273–304, 1995.
- A. K. Cheetham and R. Seshadri. Artificial intelligence driving materials discovery? Perspective on the article: Scaling deep learning for materials discovery. *Chemistry of Materials*, 36, 2024. doi: 10.1021/acs.chemmater.4c00643. Available: <https://escholarship.org/content/qt9qx9t3kz/qt9qx9t3kz.pdf>.
- D. Choudhury, S. Williamson, A. Goliński, N. Miao, F. B. Smith, M. Kirchhof, Y. Zhang, and T. Rainforth. BED-LLM: Intelligent information gathering with LLMs and Bayesian experimental design. In *International Conference on Learning Representations*, 2026. arXiv:2508.21184.
- K. Darvish, M. Skreta, Y. Zhao, N. Yoshikawa, S. Som, M. Bogdanovic, Y. Cao, H. Hao, H. Xu, A. Aspuru-Guzik, A. Garg, and F. Shkurti. ORGANA: A robotic

- assistant for automated chemistry experimentation and characterization, 2024. arXiv:2401.06949; also in *Matter* (Cell Press) 2025.
- T. Feng, Q. V. Le, T. Luong, T. H. Trinh, G. Bingham, D. Hwang, Y. Chervonyi, et al. Towards autonomous mathematics research. arXiv preprint arXiv:2602.10177, 2026. arXiv:2602.10177.
- A. Foster, M. Jankowiak, E. Bingham, P. Horsfall, Y. W. Teh, T. Rainforth, and N. Goodman. Variational Bayesian optimal experimental design. In *Advances in Neural Information Processing Systems*, 2019. arXiv:1903.05480.
- A. Foster, D. R. Ivanova, I. Malik, and T. Rainforth. Deep adaptive design: Amortizing sequential Bayesian experimental design. In *International Conference on Machine Learning*, 2021. arXiv:2103.02438.
- J. Geng, H. Chen, D. Arumugam, and T. L. Griffiths. Are large language models reliable AI scientists? assessing reverse-engineering of black-box systems, 2025. arXiv:2505.17968.
- S. Ghosal and A. van der Vaart. *Fundamentals of Nonparametric Bayesian Inference*. Cambridge Series in Statistical and Probabilistic Mathematics. Cambridge University Press, 2017.
- J. Gottweis, W.-H. Weng, A. Daryin, T. Tu, P. Sirkovic, A. Myaskovsky, G. Glowatyj, F. Weissenberger, A. Orlandi, D. Popovici, et al. Accelerating scientific discovery with Co-Scientist. *Nature*, 2026. doi: 10.1038/s41586-026-10644-y. arXiv:2502.18864.
- P. S. Gromski, A. B. Henson, J. M. Granda, and L. Cronin. How to explore chemical space using algorithms and automation. *Nature Reviews Chemistry*, 3:119–128, 2019. doi: 10.1038/s41570-018-0066-y.
- InternAgent Team, Shanghai Artificial Intelligence Laboratory. InternAgent: When agent becomes the scientist – building a closed-loop system from hypothesis to verification. arXiv preprint arXiv:2505.16938, 2025. arXiv:2505.16938v3. Circulated as NovelSeek in earlier versions; the key is retained for continuity with prior citations of this work.
- L. P. Kaelbling, M. L. Littman, and A. R. Cassandra. Planning and acting in partially observable stochastic domains. *Artificial Intelligence*, 101(1-2):99–134, 1998.
- K. Kandasamy, G. Dasarathy, J. B. Oliva, J. Schneider, and B. Póczos. Multi-fidelity Bayesian optimisation with continuous approximations. In *Proceedings of the 34th International Conference on Machine Learning*, volume 70 of *Proceedings of Machine Learning Research*, pages 1799–1808, 2017.
- S. Kim, D. Yoon, K. Gashteovski, J. Suk, J. Baek, P. Aggarwal, I. Wu, et al. On the limits and opportunities of AI reviewers: Reviewing the reviews of Nature-family papers with 45 expert scientists. arXiv preprint arXiv:2605.20668, 2026.
- R. D. King, K. E. Whelan, F. M. Jones, P. G. K. Reiser, C. H. Bryant, S. H. Muggleton, D. B. Kell, and S. G. Oliver. Functional genomic hypothesis generation and experimentation by a robot scientist. *Nature*, 427(6971):247–252, 2004. doi: 10.1038/nature02236.
- J. Liu et al. The last human-written paper: Agent-Native research artifacts. arXiv preprint arXiv:2604.24658, 2026. arXiv:2604.24658.
- Y. Liu, Z. Yang, T. Xie, J. Ni, B. Gao, Y. Li, S. Tang, W. Ouyang, E. Cambria,

- and D. Zhou. ResearchBench: Benchmarking LLMs in scientific discovery via inspiration-based task decomposition, 2025. arXiv:2503.21248; Findings of ACL 2026.
- C. Lu, C. Lu, R. T. Lange, J. Foerster, J. Clune, and D. Ha. The AI Scientist: Towards fully automated open-ended scientific discovery. arXiv preprint arXiv:2408.06292, 2024.
- C. Lu, C. Lu, R. T. Lange, Y. Yamada, S. Hu, J. Foerster, D. Ha, and J. Clune. Towards end-to-end automation of AI research. *Nature*, 651:914–919, 2026. doi: 10.1038/s41586-026-10265-5.
- B. S. Manning, K. Zhu, and J. J. Horton. Automated social science: Language models as scientist and subjects. Working Paper 32381, National Bureau of Economic Research, 2024. arXiv:2404.11794.
- A. Merchant, S. Batzner, S. S. Schoenholz, M. Aykol, G. Cheon, and E. D. Cubuk. Scaling deep learning for materials discovery. *Nature*, 624:80–85, 2023.
- L. Moreau and P. Missier. PROV-DM: The PROV data model. W3c recommendation, World Wide Web Consortium, 2013. URL <https://www.w3.org/TR/prov-dm/>.
- O. O’Donoghue, A. Shtedritski, J. Ginger, R. Abboud, A. E. Ghareeb, J. Booth, and S. G. Rodrigues. BioPlanner: Automatic evaluation of LLMs on protocol planning in biology. arXiv preprint arXiv:2310.10632, 2023. EMNLP 2023.
- G. Panapitiya, E. Saldanha, H. Job, and O. Hess. AutoLabs: Cognitive multi-agent systems with self-correction for autonomous chemical experimentation, 2025. arXiv:2509.25651.
- R. Parasuraman, T. B. Sheridan, and C. D. Wickens. A model for types and levels of human interaction with automation. *IEEE Transactions on Systems, Man, and Cybernetics—Part A: Systems and Humans*, 30(3):286–297, 2000. doi: 10.1109/3468.844354.
- T. Rainforth, A. Foster, D. R. Ivanova, and F. B. Smith. Modern Bayesian experimental design. *Statistical Science*, 2024. arXiv:2302.14545.
- E. Real, C. Liang, D. So, and Q. Le. AutoML-Zero: Evolving machine learning algorithms from scratch. In *International Conference on Machine Learning*, 2020. arXiv:2003.03384.
- B. Romera-Paredes, M. Barekatin, A. Novikov, M. Balog, M. P. Kumar, E. Dupont, F. J. R. Ruiz, J. Ellenberg, P. Wang, O. Fawzi, et al. Mathematical discoveries from program search with large language models. *Nature*, 625:468–475, 2024.
- S. Schmidgall, Y. Su, Z. Wang, X. Sun, J. Wu, X. Yu, J. Liu, M. Moor, Z. Liu, and E. Barsoum. Agent Laboratory: Using LLM agents as research assistants. arXiv preprint arXiv:2501.04227, 2025.
- J. Song, Y. Chen, and Y. Yue. A general framework for multi-fidelity Bayesian optimization with Gaussian processes. In *Proceedings of the 22nd International Conference on Artificial Intelligence and Statistics*, volume 89 of *Proceedings of Machine Learning Research*, pages 3158–3167, 2019.
- A. Sparkes, W. Aubrey, E. Byrne, A. Clare, M. N. Khan, M. Liakata, M. Markham, J. Rowland, L. N. Soldatova, K. E. Whelan, M. Young, and R. D. King. Towards robot scientists for autonomous scientific discovery. *Automated Experimentation*, 2(1):1, 2010. doi: 10.1186/1759-4499-2-1.

- N. J. Szymanski, B. Rendy, Y. Fei, R. E. Kumar, T. He, D. Milsted, M. J. McDermott, M. Gallant, E. D. Cubuk, A. Merchant, H. Kim, A. Jain, C. J. Bartel, K. Persson, Y. Zeng, and G. Ceder. An autonomous laboratory for the accelerated synthesis of inorganic materials. *Nature*, 624:86–91, 2023. doi: 10.1038/s41586-023-06734-w.
- T. Taniguchi, S. Takagi, J. Otsuka, Y. Hayashi, and H. T. Hamada. Collective predictive coding as model of science: Formalizing scientific activities towards generative science. *Royal Society Open Science*, 12(6):241678, 2025. doi: 10.1098/rsos.241678. arXiv:2409.00102.
- G. Tie, P. Zhou, and L. Sun. A survey of AI scientists: Surveying the automatic scientists and research. arXiv preprint arXiv:2510.23045, 2025.
- S.-M. Udrescu and M. Tegmark. AI Feynman: A physics-inspired method for symbolic regression. *Science Advances*, 6(16):eaay2631, 2020.
- J. Wei, Y. Yang, X. Zhang, Y. Chen, X. Zhuang, Z. Gao, D. Zhou, G. Wang, et al. From AI for science to agentic science: A survey on autonomous scientific discovery. arXiv preprint arXiv:2508.14111, 2025. arXiv:2508.14111v2.
- Workflow Run RO-Crate Community. Workflow run RO-Crate profile. https://www.researchobject.org/workflow-run-crate/profiles/workflow_run_crate/, 2023. Specification, version 0.5.
- I. Yanai and M. Lercher. Night science. *Genome Biology*, 20(1):179, 2019. doi: 10.1186/s13059-019-1800-6.
- K. J. S. Zollman. The epistemic benefit of transient diversity. *Erkenntnis*, 72(1): 17–35, 2010.

AI 참여 체크리스트

이 체크리스트는 CAISc 2026이 요구하는 대로 이 연구의 각 단계에서 AI 시스템의 역할을 문서화한다.

- **가설 개발.** 핵심 Servo 프레임워크 (S, G, E, V, M, π), 인간 권한 표현, G 출력 스펙트럼(명제 가설 $\rightarrow$ 반증 가능한 구성), 세 가지 미해결 문제는 인간 저자가 구상했다. Claude Code(Anthropic)는 프레임워크 구성요소를 정교화하고, 각 구성요소의 논문 수준 구체화를 식별하며, 개념 간 연결을 제안했다.
- **문헌 검색 및 선택.** 인간 저자가 포함 기준과 대상 시스템을 결정했다. Claude Code는 자율적으로 40개 이상의 전문 PDF를 검색, 열람하고, 논문들을 분류학으로 범주화하며, 원문 대비 주장 수준의 검증을 수행했다.
- **분석.** Claude Code는 1차 자료에서 versioned case 여섯 개와 출처 anchor 일곱 개의 record를 추출했다. 별도의 동결된 42세션·3벤더 다중 코더 audit은 14개 source-defined record를 당시 rubric으로 코딩했다. 인간 저자는 추출을 검토·수정했다. 현재 record는 출처 provenance를 가진 저자 주도 종합이며 독립 인간 gold standard가 아니다.
- **작성.** Claude Code가 이 원고의 대부분을 초안 작성했다. 인간 저자는 핵심 개념적 단락(특히 §7 및 §4의 핵심 정의)을 제공하고, 구조적 결정을 지시하며, 모든 초안을 검토했다.

전반적으로, 분업의 특성은 다음과 같다: 인간 저자는 지적 방향, 프레임워크 설계, 최종 판단을 제공했고; Claude Code는 문헌 검색, 분석 실행, 텍스트 생성을 담당했다.

책임 및 재현성 체크리스트

- **주장과 증거.** 모든 경험적 주장은 인용된 1차 자료에 근거한다. 주요 주장은 원본 PDF의 직접 전문 열람으로 검증되었다.
- **한계.** 이 논문은 기존 출판 시스템의 개념적 메타 분석이며 독창적인 실험을 포함하지 않는다. 여섯 case는 framework 개발에 사용됐고 일곱 anchor는 complete held-out graph가 아닌 partial record다. 전향적으로 동결된 contract를 미사용 case에 end-to-end 적용한 결과는 아직 없으므로 현재 근거는 내부 정합성과 표준 mapping을 지지할 뿐 out-of-sample portability를 입증하지 않는다. 선정된 case와 anchor는 구성타당성, 모집단 일반화 또는 다른 framework 대비 우월성도 검증하지 않는다.
- **실험 결과 재현성: 아니오—아직 아님.** 이 논문에는 계산 실험이 없지만 주요 case annotation과 closure predicate는 Servo event-artifact package에 의존한다. 이전 공개 snapshot은 <https://github.com/ysys143/servo-caisc2026/releases/tag/servo-corrected-v2.0.0>에 있으나 이번에 명확해진 predicate/status contract와 수정된 status matrix보다 앞선다. 현재 successor package가 불변 공개 release로 게시되기 전까지 수정 결과는 외부에서 완전히 재현할 수 없다.
- **실험 세부사항.** 문헌 검토 방법론은 Muka et al. (2020) 24단계 체계적 검토 지침을 따른다. 시스템 선택 기준: 가설-실험-검증 루프의 최소 하나의 구성요소를 자동화한다.
- **데이터 및 코드 공개 접근: 아니오—아직 아님.** 이전 공개 snapshot은 접근 가능하지만 현재 작업 tree의 명확해진 predicate contract, provenance crosswalk와 수정 status를 포함하지 않는다. 현재 case, endpoint, artifact, event, edge, reliability, closure-witness, closure-status, domain-anchor, selection-ledger, code, table과 manuscript를 하나의 successor release가 결속하기 전까지 현재 분석에 대한 공개 접근은 불완전하다.
- **윤리적 및 사회적 영향.** 인간 권한 벡터는 현재 시스템에서 인간 감독의 기능별 역할을 명시적으로 다룬다. §7은 다중 충실도 통합 및 검증된 자동 신규성 게이트의 현재 부재와 관련된 조기 수렴 위험을 논의한다.

A 교차 시스템 코딩 신뢰도

Servo event-artifact schema가 현재의 규범적 contract다. 다섯 lineage의 versioned case 여섯 개에 대해 endpoint, artifact, event, edge, reliability evaluation, predicate별 witness와 status를 기록하고, 동결된 출처 anchor 일곱 개 및 selection ledger를 둔다. 네 closure predicate는 집합값이며 case·version·configuration·task regime으로 제한된다. 하나의 저장된 loop label은 권위가 없다. Record는 저자가 해석한 출처 annotation이며 구조 검증은 의미적 entailment, 구성타당성 또는 과학 성과를 확립하지 않는다.

서로 다른 벤더의 모델 고정 LLM 코더 3개가 과거 rubric으로 14개 source-defined record(13개 lineage)를 코딩했다. 당시 Fleiss 통계는 과거 Vcalibrated $\kappa=0.79$, 루프 상태 0.74, semantic-validation 존재 1.0, 전체론적 V-완결성 0.39였다. 이 수치는 폐기된 코딩 필드에만 적용되며 최종 facet의 신뢰도가 아니다.

후속 2-vendor 재코딩의 raw 일치 13/14와 Cohen $\kappa=0.86$ 은 과거 present-versus-gating 구분, 특히 AI Scientist(Nature 2026) reviewer 역할의 사후 정제를 기록할 뿐 최종 다중 facet

taxonomy의 reliability study가 아니다. 따라서 V_{present} , V_{gating} , $V_{\text{calibrated}}$ 열은 이전 분석 재구성용으로만 남긴다.

동결된 42세션·3벤더 다중 코더 audit은 당시 manual과 로컬 PDF 근거 packet으로 14개 source record를 코딩했지만 현재 event-artifact schema보다 앞선 역사적 개발 audit이다. Record-level facet token의 agreement는 현재 event, artifact, edge, predicate와 witness의 재현성을 지지하지 않는다. 현재 여섯 case와 일곱 anchor는 저자의 별도 source-grounded 종합이며 네 번째 coder나 gold standard가 아니다. ‘None identified’는 제한된 출처에서 별도 record를 찾지 못했다는 뜻이지 부재가 입증됐다는 뜻이 아니다. 그 provenance는 수정이력 부록에 보존한다.

B 도메인별 분석

이 부록은 표 4의 선정·동결 anchor를 출처 국소적으로 풀어 쓴다. 각 항목은 하나의 이름 붙은 시스템과 하나의 제한된 1차 출처에 대응하며 domain-level 일반화나 공통 outcome 척도를 만들지 않는다.

FunSearch. Romera-Paredes et al. [2024]의 제한 계산과제에서 program 생성과 실행가능 scoring을 기록한다. Field novelty나 발견 주기 피드백 일반을 주장하지 않는다.

AI Feynman. Udrescu and Tegmark [2020]의 자료 기반 equation 탐색은 문제 국소 평가를 보여줄 뿐 cross-task transfer를 확립하지 않는다.

ChemCrow. Bran et al. [2024]의 tool 사용과 화학 실행 증거를 기록한다. Wet-lab 특성화는 artifact와 protocol별 경계로 남는다.

GNoME. Merchant et al. [2023]의 DFT·불확실성 유도 탐색을 기록한다. 계산 안정성은 합성이나 기능 특성화가 아니며 DFT도 물리 oracle이 아니다 [Cheetham and Seshadri, 2024].

BioPlanner. O’Donoghue et al. [2023]의 protocol artifact 생성을 기록한다. Protocol text만으로 biological-validity feedback witness가 확립되지는 않는다.

Manning 자동 사회과학. Manning et al. [2024]의 제한된 자동 workflow와 통계 검정을 기록한다. 이는 사회과학 전반의 표본이나 결과가 아니다.

AutoML-Zero. Real et al. [2020]의 실행가능 benchmark feedback을 기록한다. Benchmark 성능은 해석 가능성을 확립하지 않는다.

C 제출 후 수정 상태

영문 부록 D는 기록본 이후의 변경을 R1-R32로 누적해 보존한다. 한국어 정보에서는 현재 의미론과 공개 상태를 바꾸는 마지막 세 항목을 다음과 같이 기록한다.

R30. 이식 가능한 event-evidence contract와 제한된 case identity (초록; §4, §5, §6; 부록 A).

기록본 상태: 실질적으로 불충분하게 명세됐으며, 제출 후 Schema 1 해석도 지나치게 거칠었다. 기록본과 R29까지의 수정은 system record와 routed validator channel을 충분한 현재 단위로 보고 이질적 feedback을 하나의 computational-closure 판정으로 압축했다. Witness 전체에서 version, configuration, task-regime identity를 요구하지 않았고 runtime event와 reliability study를 구분하지 않았으며 versioned artifact와 artifact revision도 명시적으로 표현하지 않았다. Schema 2.0은 여섯 구성요소 core를 보존하면서 O_{env} , artifact 상태 A , 선택적 artifact 합성·수정 interface W_A 를 경계에 둔다. Event-artifact graph와 다섯 집합값 predicate—실행 복구, 실험 적응, 산출물 수정, 발견 주기 피드백, 인간 매개 피드백—를 정의하고 보수적인 출처 추적 witness를 요구한다. 적용 범위도 다섯 lineage의 versioned case 여섯 개와 선정·동결된 출처 anchor 일곱 개로 다시 기술한다. 이 수정은 진단 기술의 identity, provenance와 반증 가능성을 높이지만 schema를 검증하거나 과학 성과를 확립하고, 모집단을 추정하거나 인과를 추론하며, 비교 우월성을 보이지 않는다.

R31. 로컬 재현성 package 상태 (책임 및 재현성 체크리스트; 부록 A). 기록본 상태: 부재하며, 이후 제출 후 문구도 공개 가용성을 과장했다. 기록본에는 Schema 2.0이 포함되지 않았다. 규범 schema와 case, endpoint, artifact, event, edge, reliability, closure-witness, closure-status, domain-anchor, selection-ledger record를 포함한 완전한 작업 tree package가 현재 로컬에는 존재한다. 그러나 그 완전한 package의 공개 저장소 snapshot이나 DOI는 아직 확인되지 않았고, package는 게시되지 않았으며 공식 기록의 일부도 아니다. 따라서 재현성과 공개 접근 checklist 답을 “아니오—아직 아님”으로 바꾼다. 이 정정은 로컬 준비와 공개 가용성을 분리하며, 논문의 진단적 논지를 바꾸거나 외부 재현, 동료 검증 또는 공식 정보표 연결을 제공하지 않는다.

R32. Predicate conformance과 provenance. 범위: 관련 연구; §4, §5, §8; 재현성 checklist. 기록본 상태: 부재하며, 이전 제출 후 contract는 discovery-cycle feedback만 완전한 pattern으로 명시하고 source silence와 negative evidence를 구분하지 않았다. 다섯 predicate 모두의 최소 graph pattern을 정의하고 established, unknown, not-established, not-applicable에 machine-readable decision basis를 추가했다. Source silence에 근거한 negative status는 unknown으로 재분류했다. 기본 객체와 relation은 PROV-DM과 Workflow Run RO-Crate에 대응시키고 Servo의 추가 기여를 scientific diagnostic semantics로 제한했다. 여섯 complete case는 formative이고 일곱 anchor는 partial이므로 전향적 held-out full instantiation에 의한 portability는 아직 입증되지 않았다고 명시한다. 공개 2.0.0 snapshot은 이 변경보다 앞서므로 현재 분석은 synchronized successor release가 게시될 때까지 “아니오—아직 아님”이다.

R33. Closure 축 정정과 표현 간 정합성. 범위: 초록; §4; §5; Appendix A; 공개 분석 package. 정정 전 상태: feedback 제공 actor와 feedback path topology가 혼합돼 있었고, AI Scientist 2026의 실험 적응 셀은 출처가 명시한 실행 transition을 누락했다. 인간 mediation은 다섯 번째 closure predicate가 아니라 별도 actor facet으로 옮겨졌다. 남은 네 predicate는 path topology를 기술한다. Event class와 edge type에는 여섯

구성요소 actor 및 source-destination 쌍과의 정합성 제약을 둔다. AI Scientist 2026의 experimental-adaptation status는 metric·plot 기반 node 선택 뒤 child code 생성과 병렬 실행이 보고되므로 established로 정정한다. 다만 명시적 epistemic update와 두 번째 evidence occurrence가 없으므로 discovery-cycle feedback으로 승격하지 않는다.

수정 범위와 현재 해석. 영문 변경이력의 R1-R33가 기록본과 현재본 사이의 전체 수정 범위다. R30은 Schema 1을 현재 의미론으로서 대체하고, R31은 당시의 로컬 package 상태를, R32는 공개 2.0.0 snapshot 이후 명확해진 predicate·status contract와 successor release 필요성을 기록한다. 따라서 R23의 executor는 여섯 구성요소 core와 경계 객체 O_{env} 의 분리로, R24의 agreement는 역사적 개발 audit으로, R25-R29의 여섯-case 기술은 현재 versioned case·event·artifact·edge·predicate record로 읽는다. 여섯 구성요소 label과 세 전향적 설계 질문은 유지되지만 interface와 operationalization은 제한된 identity, versioned artifact, W_A , typed event·edge와 predicate별 witness를 포함하도록 실질적으로 바뀌었다. 이전 항목에서 “final”이라 부른 Schema 1 표나 단일 closure label은 현재 의미 입력이 아니다. 이 supersession은 이전 항목의 역사적 문구나 연대기를 고치지 않는다.