

AI 과학자 시스템의 형식화: 구성요소 프레임워크와 이론적 분석

Jaesol Shin
WeDataLab
ysys143@wedatalab.com

2026년 5월

Abstract

가설 생성, 실험 실행, 지식 합성을 자동화하는 엔드투엔드 시스템의 등장은 과학이 수행되는 방식에 중대한 변화를 가져오고 있다. 빠른 경험적 발전에도 불구하고, 최근 LLM 기반 AI 과학자 시스템들은 공유된 형식 어휘 안에서 분석되는 경우가 드물어 아키텍처 및 과학 도메인 간 원칙적 비교가 어렵다. 본 논문은 Servo, 즉 탐색 공간(Search space), 가설 생성기(hypothesis Generator), 실험 실행기(Experiment executor), 검증기(Validator), 메모리(Memory), 탐색 정책(search Policy, π)의 여섯 구성요소로 이루어진 프레임워크(S, G, E, V, M, π)를 제안한다. 이 프레임워크는 부분 관측 마르코프 결정 과정(POMDP) 이론과 베이지 실험 설계(BED) 이론에 기반한다. 본 논문은 핵심 AI 과학자 시스템 및 일곱 개 과학 도메인(수학, 물리학, 화학, 재료과학, 생물학, 사회과학, 컴퓨터 과학)에 걸친 구체적인 적용을 분석하고, 이러한 시스템의 출력 형식과 검증 계층을 다루는 상호 보완적인 아티팩트 인프라 제안도 별도로 검토한다. 분석을 통해 세 가지 지속적인 미해결 문제가 도출된다: (1) 신규성 평가의 자동화 불가능성—다층적 자동화 프로세스에도 불구하고 인간 판단에 여전히 의존; (2) BED 최적 탐색 정책의 부재—실험 가능한 근사 방법이 이론적으로 존재함에도 불구하고; (3) 의미 메모리 M_s 의 미성숙—축적된 실험 경험이 미래 탐색을 개선하지 못하는 문제. 본 논문은 검증기 V 의 중심적 역할을 형식화한다: 다루기 쉽고 식별 가능한 가정 하에서 발견 루프는 증명 가능하게 닫히고(보정된 검증기는 탐색 정책을 근시안적으로 최적화한다), 믿음 갱신에 잘못 결합된 검증기는 잘못된 표적으로의 수렴을 유발하며, 신규성은 어떤 자동 검증기로도 식별 불가능하다(명제 1-3). 조사된 시스템과 도메인 전반에서 검증기 완결성은 페루프 가능성과 일관되게 연관되며, 우리는 이 서베이를 독립적 경험 증명이 아니라 형식 결과의 예시로 제시하고, 현재 AI 과학자 시스템들을 더 완전한 검증기를 향한 진행으로 해석한다.

1 서론

AI 과학자 시스템—가설을 독립적으로 생성하고, 실험을 실행하며, 지식을 합성하는 에이전트—은 급속도로 증가하고 있으나 [Boiko et al., 2023, Lu et al., 2024, 2026, Schmidgall et al., 2025, Feng et al., 2026, Liu et al., 2026], 이 분야는 공통된 형식 어휘가 부재하다. 각 시스템은 고유한 용어를 도입하여 체계적인 비교를 어렵게 한다. 실제 배포에 직결되는 세 가지 질문이 여전히 미답 상태이다: 어떤 요소가 시스템의 페루프 운영 가능 여부를 결정하는가? 자율적 신규성 평가는 왜 지속적으로 실패하는가? 이론적으로 최적인 탐색 정책은 무엇인가?

본 논문은 세 가지 기여로 이 격차를 해소한다: (1) Servo, AI 과학자 시스템을 POMDP 및 베이지 실험 설계 이론과 연결하는 형식 프레임워크 (S, G, E, V, M, π) (§4); (2) 네 개의 핵심 시스템, 아티팩트 인프라 제안, 그리고 일곱 개 과학 분야에 걸친 도메인별 구체화 분석 (§5, §6); (3) 모든 현재 시스템에 걸쳐 진전을 제약하는 세 가지 미해결 문제 (§7).

범위. 본 논문은 가설-실험-검증 주기를 통해 과학적 발견을 자동화하는 것이 주된 목표인 시스템을 다루며, 인간 주도 파이프라인 내 특화 도구 [Jumper et al., 2021]는 제외한다.

2 배경

Kaelbling et al. [1998]의 POMDP 정식화에 따라, AI 과학자 시스템을 부분 관측 마르코프 결정 과정으로 모델링한다: 진상태 s (자연의 미지 구조)는 직접 접근 불가능하며; 시스템은 실험적 관측으로 업데이트되는 믿음 상태 $b(s)$ 를 유지한다. 형식적으로, AI 과학자 POMDP는 튜플 $(S, \mathcal{A}, T, R, \Omega, \mathcal{O}, b_0, \gamma)$ 이며, 여기서 $\mathcal{A}$ 는 행동 공간(가설 생성 및 실험 실행), T 는 전이 함수, R 은 보상(발견의 과학적 가치), $\mathcal{O}$ 는 잡음이 있는 관측 과정, b_0 는 초기 믿음, γ 는 할인 인자이다. 믿음은 베이지 규칙 $b'(s') \propto \mathcal{O}(o | s', a) \sum_s T(s' | s, a) b(s)$ 로 갱신되며, π 는 접근 불가능한 상태 s 가 아니라 믿음 b 에 따라 행동한다. 세 가지 속성이 표준 제어 문제와 구별한다: R 은 사전에 명시될 수 없다(유의성은 선형적으로 정의되지 않음); S 는 무한하다; T 는 비정상적이다(축적된 지식이 탐색 전선을 변화시킴). 따라서 우리는 POMDP를 개방형 과학의 완전히 명시된 모델이 아니라 조직화 형식으로 사용한다: §4.1의 형식 결과는 이 일탈들이 제한되는 다루기 쉬운 하위문제(가정 1)에서 성립하며, 일반적 개방형 경우는 미해결로 남긴다. 베이지 실험 설계(BED) [Chaloner and Verdinelli, 1995, Rainforth et al., 2024]는 탐색 정책 π 의 규범적 기준을 제공한다: 기대 정보 이득(EIG)을 최대화하는 d^* 를 선택하고,

$$d^* = \arg \max_{d \in \mathcal{D}} \text{EIG}(d) = \arg \max_d \mathbb{E}[H(\theta) - H(\theta | y, d)] \quad (1)$$

여기서 $H(\theta)$ 는 매개변수 θ 에 대한 사전 엔트로피이고, $H(\theta | y, d)$ 는 d 하에서 y 를 관측한 후의 기대 사후 엔트로피이다. EIG는 변분 방법 [Foster et al., 2019], 분할 상환 정책 [Foster et al., 2021], 강화학습 [Blau et al., 2022]으로 근사할 수 있으나, 현재 어떤 AI 과학자 시스템도 이를 구현하지 않는다—§7에서 다루는 격차이다.

3 관련 연구

AI 과학자 시스템. 선행 연구 [Lu et al., 2024, 2026, Schmidgall et al., 2025, Boiko et al., 2023]는 개별 시스템에 대한 정성적 특성화를 제공하지만 교차 시스템 비교를 위한 공통 프레임워크는 없다; 아이디어 생성 연구 [Si et al., 2024, Baek et al., 2024]는 완전한 발견 루프를 통합하지 않은 채 품질 기준선을 수립한다.

자율 과학 프레임워크. 페루프 자율 발견은 LLM 시대에 선행한다: Robot Scientist [Sparkes et al., 2010]는 효모 기능유전체학에서 가설 생성, 로봇 실험, 통계적 검증을 통합하여 LLM 기반 시스템보다 10년 이상 앞서 Servo의 여섯 구성요소 전체—능동학습 정책 포함—를 물리적 습식 실험실 형태로 구체화했다. 보다 최근의 통합 프레임워크로는 아이디어 생성에서 검증까지 12개 과학 과제에 걸친 페루프 다중 에이전트 시스템 NovelSeek [Zhang et al., 2025]와 생물의학 wet-lab 검증을 갖춘 다중 에이전트 가설 생성 시스템 Co-Scientist [Gottweis et al., 2026]가 있다. 따라서 우리는 Servo를 자동 발견을 위한 최초의 통합 프레임워크가 아니라, 검증기 완결성·의미

메모리·POMDP/BED 관계를 최근 LLM 에이전트 하위 분야 안에서 명시화하는 형식적 어휘로 위치시킨다.

이론적 기반. POMDP 프레임워크 [Kaelbling et al., 1998]와 BED [Chaloner and Verdinelli, 1995, Rainforth et al., 2024]는 고전적이다. 베イズ 최적 실험 선택은 자동 과학에서 오랜 역사를 가지며—가장 직접적으로는 Robot Scientist의 능동학습 정책 [Sparkes et al., 2010]에서—본 논문은 이 전통 위에서 POMDP(구조적 정식화)와 BED(규범적 정책 기준)를 현대 LLM 에이전트 환경에 대해 연결하며, 이 아이디어 자체의 선취권을 주장하지는 않는다.

과학의 형식 모델과 아티팩트 인프라. Taniguchi et al. [2025]는 집합적 예측 코딩을 과학의 사회적 모델로 제안한다; 본 논문은 상호 보완적인 단일 시스템 모듈형 분해를 제공한다. Liu et al. [2026]은 §5.1 및 §7에서 논의되는 V 및 M_s 기여로서 아티팩트 검증을 다룬다.

4 Servo 프레임워크

AI 과학자 시스템을 다음 구성요소를 가진 튜플 (S, G, E, V, M, π) 로 정의한다:

$$\text{Servo} = (S, G, E, V, M, \pi) \quad (2)$$

S : 탐색 공간 (Search Space) 탐색 대상인 후보 가설, 프로그램, 분자, 실험 조건 또는 기타 객체의 집합. S 는 정적이거나 동적으로 확장(개방형)될 수 있다.

$G: M \times S \rightarrow h$: 가설 생성기 (Hypothesis Generator) 축적된 메모리 M 과 탐색 공간의 현재 상태를 조건으로 새로운 후보 $h \in S$ 를 제안하는 함수. G 는 LLM 생성, 진화적 돌연변이, 또는 기호적 탐색을 수반할 수 있다.

$E: h \times P \rightarrow o$: 실험 실행기 (Experiment Executor) 프로토콜 P 하에서 가설 h 를 실행하여 관측 o 를 생성하는 함수. E 의 충실도는 빠른 계산 시뮬레이션(낮은 비용, 잠재적 대리 오차)에서 물리적 습식 실험실 실행(높은 비용, 실제 정답)까지 다양하다.

$V: o \rightarrow r$: 검증기 (Validator) 관측 o 에 보상 신호 r 를 할당하는 함수. V 의 네 계층을 구별한다:

$$\begin{aligned} V_{\text{syntax}}: o &\rightarrow \{\text{pass}, \text{fail}\} && (\text{결정론적, 고속}) \\ V_{\text{semantic}}: o &\rightarrow r \in [0, 1] && (\text{LLM 기반, 확률적}) \\ V_{\text{empirical}}: o &\rightarrow r && (\text{재현 기반}) \\ V_{\text{human}}: o &\rightarrow \{\text{novel}, \text{significant}\} && (\text{자동화 불가}) \end{aligned}$$

M : 메모리 (Memory) (M_e, M_s, M_p) 로 구성. M_e (일화)는 개별 기록 (h_i, o_i, r_i) 를 저장; M_s (의미)는 증류된 지식 패턴을 저장; M_p (절차)는 학습된 프로토콜을 저장. M 의 구조는 G 와 π 의 품질을 직접 결정한다.

$\pi: b(S) \times M \rightarrow h$: 탐색 정책 (Search Policy) 다음 가설을 선택하는 결정 규칙. 믿음 상태 $b(S)$ 는 각 실험 후 업데이트된다. BED 해석에서 $\pi^* = \arg \max_d \text{EIG}(d)$ (식 1). 실제로는 반응형(ReAct)에서 탐욕적, 트리 탐색까지 다양한 정책이 사용된다.

운영 루프는 다음과 같다:

$$\begin{aligned} \pi(b, M) &\rightarrow G(M_s, S) \rightarrow E(h, P) \rightarrow V(o) \\ &\rightarrow M += (h, o, r) \rightarrow b(S) \text{ 업데이트} \rightarrow \text{반복} \end{aligned} \quad (3)$$

인간 개입 정도를 나타내는 보조 매개변수 $H \in [0, 1]$ 을 추가로 도입한다: $H = 0$ 은 완전 자율 시스템, $H = 1$ 은 인간이 G 또는 π 의 역할을 맡는 시스템이다.

4.1 검증기 완결성: 형식적 분석

V 를 쉽게 혼동되는 두 대상으로 분리하여 그 역할을 정밀화한다: 베이지 믿음 갱신을 구동하는 관측 가능도 $p(o \mid \theta, d)$ 와, 정책 π 가 결과를 점수화하는 데 쓰는 보상 추정치 검증기 $V(o)$. 아래 결과는 다루기 쉬운 하위문제에서 성립하며, 개방형 영역은 미해결로 남긴다.

가정 1 (다루기 쉽고 식별 가능한 하위문제). (i) 탐색 공간 S 가 유계이고 매개변수 공간 Θ 가 콤팩트하다; (ii) T 가 정상적이다; (iii) 사전 분포 $p(\theta)$ 의 받침이 참값 θ^* 를 포함한다; (iv) 관측 모델 $p(o \mid \theta, d)$ 가 올바르게 명세되어 있고 θ 를 식별한다($\theta \neq \theta'$ 이면 둘을 분리하는 도달 가능한 설계가 존재); (v) 실현된 설계 수열이 균일하게 정보적이다—무한히 자주, 생존 가설 쌍 간 쿨백-라이블러 분리가 고정된 $\delta > 0$ 이상인 도달 가능한 설계를 선택한다(동치로 누적 정보 $\sum_t \text{EIG}(d_t)$ 가 발산).

정의 1 (보상 채널로서의 검증기). $V(o)$ 는 참 보상 $R(s, a)$ 를 추정한다; $\mathbb{E}[V(o) \mid s, a] = R(s, a)$ 이면 보정됨, 어떤 (s, a) 에서 $\delta(s, a) = \mathbb{E}[V(o) \mid s, a] - R(s, a) \neq 0$ 이면 편향됨이라 한다. V 는 명시적으로 결합되지 않는 한 갱신 가능도 $p(o \mid \theta, d)$ 와 구별된다.

명제 1 (폐쇄를 위한 충분성). 가정 1 하에서 사후 분포는 θ^* 에 집중한다(루프가 닫힌다). 추가로 V 가 보정되어 있으면 일단계 EIG 규칙(식 1)이 정보 목적함수에 대해 근시안적으로 베이지 최적이다.

증명 개요. 콤팩트 Θ 위에서 올바르게 명세된 식별 가능 가능도와 발산하는 누적 정보(가정 1(i),(iv),(v))는 베이지 사후 일치성의 표준 충분조건이며 [Ghosal and van der Vaart, 2017], $b_t \rightarrow \delta_{\theta^*}$ 를 준다. 보정은 일치성에 필요하지 않으며, 기대 정보 이득의 정의상 일단계 EIG를 근시안적으로 최적화할 뿐이다. 균일 정보 조항 (v)가 본질적이다: $\text{EIG}(d_t) > 0$ 이지만 $\sum_t \text{EIG}(d_t) < \infty$ 인 수열은 식별성과 보정 하에서도 사후 분포를 점질량에 이르지 못하게 한다. $\square$

명제 2 (오설정 결합 하의 표류). 검증기가 믿음 갱신에 들어간다고 하자, 즉 유효 갱신이 결합 $\beta > 0$ 로 $q_\theta(o) \propto p(o \mid \theta, d) \exp(\beta V(o))$ 라 하자. V 가 결과에 θ -의존적(비아핀) 방식으로 의존하면 사후 분포는 쿨백-라이블러 사영 $\theta^\dagger \neq \theta^*$ 에 집중한다 [Berk, 1966]: 루프는 계산적으로 닫히지만 잘못된 표적에. V 의 θ -독립 아핀 변환(예: 상수 가산 편향)은 로그-분배함수에서 상쇄되어 θ^* 를 바꾸지 않으며, V 가 순수 정책 채널일 때($\beta = 0$)는 어떤 검증기 변환도 표적을 옮기지 못한다—기껏해야 설계 선택을 악화시키고 정보 획득을 늦출 뿐이다(가정 1(v)와 상호작용).

증명 개요. 결합된 오설정 갱신 가능도는 사후 분포를 그 KL 최소점에 놓는다 [Berk, 1966]; 로그-분배함수 $\log \int p(o \mid \theta, d) e^{\beta V(o)} do$ 는 그 θ -의존성이 바뀔 때만 최소점을 옮기며, θ -독립 아핀 항은 이를 바꾸지 않는다. $\beta = 0$ 이면 갱신 가능도가 불변이므로 θ^* 는 V 에 불변이다. $\square$

명제 3 (신규성의 비식별성). 신규성/유의성 성분 θ_{nov} 가 식별된 성분들과 사전적으로 독립이라 하자. 모든 자동 검증기의 채널 가능도가 θ_{nov} 에 의존하지 않으면, 어떤 자동 검증기도 θ_{nov} 의 일치 추정량을 갖지 못하며, 신규성에 대한 루프 폐쇄는 V_{human} 을 요구한다.

증명 개요. 가능도가 θ_{nov} 에 의존하지 않고 사전 분포가 이를 식별된 성분과 결합하지 않으면, θ_{nov} 의 사후 주변 분포는 모든 데이터에 대해 사전 분포와 같다; 따라서 식별되지 않으며 일치 추정량이 존재하지 않는다. $\square$

이 결과들은 V 완결성 해석을 과장하지 않고 그 범위를 한정한다. 완결된 검증기는 자율적 폐쇄에 필요하다—보정된 보상과, $V_{\text{empirical}}$ 의 경우 가정 1이 요구하는 식별 가능·올바르게 명세된 채널을 종종 제공한다—그러나 명제 1은 수렴이 충분한 누적 정보도 필요함을, 명제 2은 표류가 단순한 순위 변화가 아니라 잘못 결합된 검증기를 요구함을, 명제 3은 어떤 자동 검증기도 해결할 수 없는 성분을 분리해 보인다. 이어지는 서베이는 이 명제들을 예시하며 증명하지 않는다.

5 핵심 AI 과학자 시스템 분석

Servo를 네 개의 엔드투엔드 시스템 [Boiko et al., 2023, Lu et al., 2024, 2026, Schmidgall et al., 2025]과 하나의 아티팩트 인프라 제안에 적용한다. 표 1은 핵심 차원을 종합한다; 시스템 간 공통 패턴은 대부분의 아키텍처적 발전이 V 완결성 향상과 함께 나타나며, V 완결성이 페루프 운영을 가능하게 한다는 것이다(§4.1의 명제 참조).

	Robot Sci.	Coscientist	AI Sci. (2024)	AI Sci. (2026)	AgentLab	NovelSeek
신규성 측정	통계 검정	없음	LLM 자체 평가	3단계	인간 위임	성능 향상
루프 폐쇄?	예(습식)	부분적	예(탐욕적)	예(트리)	부분적	예(계산)
π 유형	능동학습	ReAct	탐욕적	트리 탐색	인간/순차	퍼드백
V 완결성	V_e	$V_h + V_e$	V_s	$V_e + V_s + V_h$	V_s (편향)	V_e
M 구조	$M_e + M_s$	일시적	M_e	$M_e + M_s$	M_e	M_e
H (인간 역할)	낮음	G	낮음	낮음	$G + \pi$	낮음

Table 1. 핵심 AI 과학자 시스템의 비교 Servo 분석(LLM 이전 Robot Scientist [Sparkes et al., 2010]와 최근 통합 프레임워크 NovelSeek [Zhang et al., 2025] 포함). V_s =의미, V_e =실증, V_h =인간.

5.1 아티팩트 인프라: 에이전트 네이티브 연구 아티팩트

Liu et al. [2026]은 상호 보완적인 문제를 다룬다: AI 과학자 루프의 출력이 어떤 모습이어야 하는지, 그리고 독립적으로 어떻게 검증될 수 있는지. 에이전트 네이티브 연구 아티팩트(ARA)는 서사적 논문을 네 계층의 온톨로지로 대체한다: /logic(반증 기준이 있는 주장), /src(실행 가능 코드), /trace(탐색 그래프: 질문, 결정, 실험, 막다른 길, 전환), /evidence(원시 결과). ARA 썰은 세 단계 자동 검증을 제공한다— V_{syntax} (스키마 적합성), V_{semantic} (엄격성 감사기, 82.6% 탐지율), $V_{\text{empirical}}$ (샌드박스 재현)— V_{human} 은 유의성, 신규성, 취향을 위해 명시적으로 유보된다: “유의성, 신규성, 취향에 대한 판단은 인간 심사위원을 위해 유보된다” [Liu et al., 2026]. 동기는 정량적이다: 출판 논문의 재현 요건 중 45.4%만이 완전히 명시되어 있고, 확장 비용의 90.2%는 실패한 탐색에 소비된다 [Liu et al., 2026]. /trace 계층은 M_e 와 M_s 를 다룬다: 보존된 실패 흔적은 에이전트의 확장 과업 성능을 가속화하지만, 동시에 더 유능한 에이전트를 이전 해결 경로에 고착시켰다—풍부한 M_e 가 π 를 단조적으로 개선하지 않는다.

6 도메인 분석

표 2은 일곱 개 과학 도메인에 걸친 Servo 구체화를 보여준다; V 완결성은 조사된 도메인 전반에서 루프 폐쇄 가능성과 공변하며, 이는 명제 1-3과 일관된다. 규모를 예시하면: Aletheia [Feng et al., 2026]는 700개의 에르되시 문제를 시도했으며, 심사위원은 200개 채점 해법 중 13개(6.5%)를 의미있게 정확하다고 평가했다; GNoME [Merchant et al., 2023]은 고처리량 DFT를 통해 220만 개의 후보 결정 구조를 검토했다. 분석 대상 시스템: 수학(형식적: [Romera-Paredes et al., 2024, Xin et al., 2024]; 자연어: [Feng et al., 2026]), 물리학 [Udrescu and Tegmark, 2020, Cranmer et al., 2020], 화학 [Bran et al., 2024, Sprueill et al., 2024], 재료과학 [Merchant et al., 2023], 생물학 [O’Donoghue et al., 2023], 사회과학 [Manning et al., 2024, Aher et al., 2023, Park et al., 2023], 컴퓨터 과학/알고리즘 [Real et al., 2020, Sartori and Blum, 2024, Jaber and Jaber, 2026].

도메인 패턴은 우연이 아니다. 수학(형식)에서, 잡음 없는 V_{formal} 은 안정적인 강화학습을 가능하게 한다: 이진적이고 명확한 보상은 해킹될 수 없다. 화학과 생물학에서, 자동화된 V 가 물리적

도메인	V 유형	V 신뢰도	루프	π	주요 병목
수학(형식)	V_{formal}	완벽 오라클	완전 폐쇄	RL/MCTS	사전훈련 오염
수학(자연어)	$V_{\text{sem}} + V_h$	불완전	부분적	순차 개선	환각; 표절
물리학	$V_{\text{emp}} + V_h$	중간	없음/부분적	결정론적	문제 간 M 없음
화학	V_{emp} (대리)	중간	계산만	빔 탐색	습식 루프 개방
재료과학	V_{emp} (DFT)	높음	계산 폐쇄	불확실성 샘플링	DFT 연산 시간; 합성 지연
생물학	$V_{\text{emp}} + V_h$	낮음-중간	부분적	없음	V 지표 불충분
사회과학	통계 검증	낮음-중간	부분적	완전 요인	순환 타당성
CS/알고리즘	V_{emp}	높음	완전 폐쇄	진화/LLM	해석 가능성 부재

Table 2. 일곱 개 도메인에 걸친 Servo 교차 도메인 분석. V 신뢰도는 실제 정답과의 일치도를 나타낸다.

측정(NMR, MS, 습식 실험실 검증)을 대체할 수 없기 때문에 루프가 폐쇄될 수 없다. 재료과학은 π 가 BED 이론에 가장 근접한 유일한 도메인이다: 추적 가능한 GNN 사후 확률에 대한 GNoME의 불확실성 샘플링이 EIG 최적 탐색에 가장 가까운 현존 배포이다. 사회과학은 별개의 실패 양식에 직면한다: G 와 E 가 동일한 기반 모델을 공유할 때, 평가자는 생성기의 암묵적 편향을 체계적으로 확인한다 [Aher et al., 2023].

7 이해결 문제

본 분석은 모든 시스템과 도메인에 걸쳐 지속되는 세 가지 이해결 문제를 식별한다.

7.1 신규성의 자동화 불가능성

신규성은 자동화된 수단으로 신뢰할 수 있게 평가될 수 없다: Coscientist(메커니즘 없음)에서 The AI Scientist Nature(3단계 검증)까지 모든 시스템이 이 결론으로 수렴한다. 두 가지 실패 양식이 문서화되어 있다: LLM 자체 평가 편향(체계적 과대 추정; 환각된 결과)과 사전훈련 오염(시스템이 훈련 데이터에 암묵적인 결과를 “발견”할 수 있음, Aletheia가 에르되시 문제에서 문서화한 것처럼). ARA 썰 [Liu et al., 2026]은 자동화 전선을 표시한다: 그 엄밀성 감사기(Rigor Auditor)는 5가지 구조적 위반 유형에 걸쳐 평균 82.6%를 탐지하지만, 고아 실험 위반은 22%만 탐지한다(두 비율은 서로 다른 분모를 측정하며 서로의 여사건이 아니다). 신규성 경계는 넘을 수 없다. 구체적으로: Agent Laboratory의 LLM 심사위원은 NeurIPS 심사 척도에서 인간 박사 연구원 대비 평균 +2.3점을 과대 추정했고; The AI Scientist(Sakana)는 절제 실험 표를 환각했으며; 700개의 에르되시 문제 중 인간 심사를 위해 선별된 200개의 해법 가운데 13개(6.5%)만이 의미있게 정확하다고 평가되었다.

반증 기준: 자동화된 V 가 ≥ 3 개 과학 도메인에 걸친 오염-통제 벤치마크에서 인간 수준의 신규성 판별(평가자 간 일치도 ≥ 0.80)을 달성하면 반증된다.

7.2 π 의 BED-실제 격차

식 1은 이론적으로 최적인 정책을 명시하지만, 현재 어떤 시스템도 이를 구현하지 않는다: 모든 배포 정책은 휴리스틱이다(ReAct, 탐욕적, 트리 탐색, 인간 주도). 부분적 예외는 GNoME [Merchant et al., 2023]으로, 추적 가능한 GNN 사후 확률에 대해 EIG를 근사하는 심층 앙상블 불확실성 샘플링을 사용한다—그러나 이는 DFT가 잘 보정된 V 를 제공하고 가설 공간이 학습 가능한 확률 모델을 허용하기 때문이며, LLM 기반 시스템에는 없는 조건으로 “사후 확률”이 모델 가중치에 암묵적으로 존재한다 [Foster et al., 2021]. 구체적으로, 표 1의 모든 시스템은 휴리스틱

π 로 저하된다: Coscientist는 반응적으로 다음 도구를 선택하고, The AI Scientist(Sakana)는 탐욕적으로 아카이브 유사성을 회피하며, Agent Laboratory는 고정된 순차 스케줄을 따른다—어떤 것도 추가 실험 데이터로 개선되지 않으며, 이것이 EIG 최적 π 가 피할 실패 양식이다.

반증 기준: 사후 확률이 제1원리로 추적 가능하지 않은 도메인에서 $p(\theta | y)$ 에 대한 사후 확률을 명시적으로 계산하고 EIG를 최대화하는 정책을 구현하는 AI 과학자 시스템이 있으면 반증된다—GNoME의 심층 양상블 정책과 같은 추적 가능 모델 프록시는 제외한다.

7.3 의미 메모리 M_s 의 미성숙

현재 시스템들은 원시 실험 기록(M_e)을 저장하지만 전이 가능한 패턴(M_s)으로 증류하지 않는다: 1,000개의 실험을 가진 시스템은 10개를 가진 시스템보다 더 지능적으로 탐색하지 않는다. ARA /trace 계층 [Liu et al., 2026]이 가장 가까운 근사이지만, 흔적은 확장 과업 성능을 가속화하는 동시에 유능한 에이전트를 이전 해결 경로에 고착시켰다— M_s 구조는 선택적 망각 메커니즘과 결합되어야 유익하다. GNoME는 도메인 내 M_s 축적이 실제로 작동할 수 있음을 보여준다: DFT 결과가 축적됨에 따라 GNN이 진정으로 개선된다. 미해결 문제는 GNoME가 멈추는 곳에서 시작된다—동일한 메모리 구조가 전체 재훈련 없이 화학이나 생물학에서 재사용될 수 없으며, 심지어 재료과학 내에서도 분포 이동 하에서 성능이 저하된다.

반증 기준: 시스템이 명시적으로 사전 훈련되거나 최적화된 도메인이 아닌 영역에서, 사전에 지정된 지표로 측정하여 축적된 교차 실험 지식이 G 생성 가설의 품질을 입증 가능하게 개선하면 반증된다.

세 미해결 문제는 독립적이지 않다. 완전한 V 와 추적 가능한 M_s 를 가진 시스템은 EIG 최적 π 에 필요한 전제 조건을 갖추게 된다: 완전한 V 는 EIG가 요구하는 보정된 보상 신호를 제공하고, 추적 가능한 M_s 는 EIG가 계산되는 가설 공간 모델을 제공한다. 이러한 전제 조건들이 비정상적이거나 무한한 S 에서 추적 가능한 EIG 추정을 위한 충분조건인지는 미결 문제이지만, 필요조건임은 분명하다. 이들은 또한 집합적 AI 공동 과학자 [Taniguchi et al., 2025]의 실현에 필요한 조건이기도 하다: $V_{\text{collective}}$ 는 신규성 자동화 가능성 해결을 요구하고; 원칙적인 집합 π 는 BED-실제 격차 해소를 요구하며; 공유 의미 메모리 w 는 발전된 M_s 를 요구한다. ARA [Liu et al., 2026]은 M_s 를 외재화하고 V 의 신규성 경계 이하 계층을 보정함으로써 두 문제를 동시에 다루는 가장 실현 가능한 진입점일 수 있다.

8 논의

V 설계는 페루프 운영의 필요 제약이다: 신뢰할 수 없는 검증은 시스템이 자신의 출력이 진전을 나타내는지 학습하지 못하게 한다. 다만 조사된 시스템들은 V 를 G , E , M , π 와 분리하지 않으므로(Coscientist와 The AI Scientist는 계획·도구 사용·트리 기반 실험도 함께 발전시킨다), 우리는 V 완결성을 인과적으로 확립된 우선순위가 아니라 반복되는 병목으로 읽는다. 집합적 확장 [Taniguchi et al., 2025]은 세 미해결 문제가 먼저 해결될 것을 요구한다: $V_{\text{collective}}$ 는 신규성 자동화 가능성을, 원칙적인 집합 π 는 BED-실제 격차 해소를, 발전된 M_s 는 공유 의미 메모리 w 를 요구하며, ARA [Liu et al., 2026]은 w 의 가장 실현 가능한 진입점일 수 있다.

한계. Servo은 E 의 도메인 특화 비용 구조(도메인에 따라 수십 배 차이), S 의 비정상성(개방형 문제), 그리고 Taniguchi et al. [2025]가 형식화한 사회적 계층을 추상화한다. 더 근본적으로 V -완결성 패턴은 인과적 결정 요인이 아니라 시스템 간 연관이며, 조사된 시스템은 선택·생존 편향이 있는 편의 표본이다. 코딩을 감사 가능하게 하기 위해 우리는 조작적 루브릭, 셀별 출처 인용이 달린 기계가독 코딩 시트, 인용이나 인용문이 없는 셀을 거부하는 검증 스크립트를 공개한다. 서로 다른 벤더(Anthropic·OpenAI·Google)의 모델 고정 블라인드 LLM 기반 코더 에이전트

3개가¹ 14개 시스템을 코딩했으며, 코더 간 일치(전원이 코딩한 13개 시스템에 대한 Fleiss' κ)는 대부분 구성개념에서 상당 완전(보정 $\kappa=0.79$, 루프 상태 $\kappa=0.74$, 의미검증 존재 $\kappa=1.0$; 평균 $\kappa=0.68$)이고 전체론적 V-완결성 순서형에서만 중간($\kappa=0.39$, 이 항목은 저자와도 불일치)이며, 인간 수준 신뢰도가 아닌 자동 다중평가자 투명성 지표로 보고한다. 반례 탐색은 V-불완전하면서 신뢰 가능한 페루프 발견을 달성하는 시스템을 찾지 못했다: 유일한 구조적 근접 사례(AI Scientist v1)는 편향된 검증기 위에서 루프를 닫지만 신뢰할 수 없는 출력을 낸다. 따라서 우리는 이 패턴을 명제 1-3로 정밀화된 연관으로 진술하며, 가장 견고하게 코딩된 하위구성개념인 보정을 결정적 상관 변수로 본다.

9 결론

본 논문은 AI 과학자 시스템을 POMDP 및 BED 이론과 연결하는 형식 프레임워크인 Servo (S, G, E, V, M, π)를 도입하고, 이를 네 개의 핵심 시스템, 하나의 아티팩트 인프라 제안, 일곱 개 과학 도메인에 적용했다. 핵심 발견은 V 완결성이 페루프 가능성의 주된 상관 변수라는 것이다: 조사된 시스템 전반에 걸쳐 대부분의 아키텍처적 발전은 V 완결성 향상과 함께 나타나며, 명제 1-3가 완결된 검증기가 올바른 루프 폐쇄에 필요한 형식적 이유를 제시한다. 세 미해결 문제의 병목은 근본적 불가능성이 아니라 누락된 아키텍처 구성요소들이다. Servo이 제공하는 것은 그것들을 정확히 명명하는 어휘다: 이 분야에는 루프를 닫기에 충분히 완전하면서도 원칙적인 탐색을 지원하기에 충분히 구조화된 검증기와 메모리 구조가 필요하다.

References

- G. V. Aher, R. I. Arriaga, and A. T. Kalai. Using large language models to simulate multiple humans and replicate human subject studies. In International Conference on Machine Learning, 2023. arXiv:2208.10264.
- J. Baek, S. K. Jauhar, S. Pitis, S. J. Hwang, and J. Teevan. ResearchAgent: Iterative research idea generation over scientific literature with large language models. arXiv preprint arXiv:2404.07738, 2024.
- R. H. Berk. Limiting behavior of posterior distributions when the model is incorrect. The Annals of Mathematical Statistics, 37(1):51–58, 1966.
- T. Blau, E. V. Bonilla, I. Chades, and A. Dezfouli. Optimizing sequential experimental design with deep reinforcement learning. In International Conference on Machine Learning, 2022. arXiv:2202.00821.
- D. A. Boiko, R. MacKnight, B. Kline, and G. Gomes. Emergent autonomous scientific research capabilities of large language models. Nature, 624:570–578, 2023.
- A. M. Bran, S. Cox, O. Schilter, C. Baldassari, A. D. White, and P. Schwaller. ChemCrow: Augmenting large-language models with chemistry tools. Nature Machine Intelligence, 2024. arXiv:2304.05376.
- K. Chaloner and I. Verdinelli. Bayesian experimental design: A review. Statistical Science, 10(3):273–304, 1995.
- M. Cranmer, A. Sanchez Gonzalez, P. Battaglia, R. Xu, K. Cranmer, D. Spergel, and S. Ho. Discovering symbolic models from deep learning with inductive biases. In Advances in Neural Information Processing Systems, 2020. arXiv:2006.11287.

¹코더: Claude Code(claude-opus-4-8, Anthropic), Codex CLI(gpt-5.5, OpenAI), Antigravity(agy, Gemini 3.1 Pro 고추론; Google). 모두 헤드리스·모델 고정이며, 정확한 호출과 모델별 출력은 보충 자료에 공개한다.

- T. Feng, Q. V. Le, T. Luong, T. H. Trinh, G. Bingham, D. Hwang, Y. Chervonyi, et al. Towards autonomous mathematics research. arXiv preprint arXiv:2602.10177, 2026. arXiv:2602.10177.
- A. Foster, M. Jankowiak, E. Bingham, P. Horsfall, Y. W. Teh, T. Rainforth, and N. Goodman. Variational Bayesian optimal experimental design. In *Advances in Neural Information Processing Systems*, 2019. arXiv:1903.05480.
- A. Foster, D. R. Ivanova, I. Malik, and T. Rainforth. Deep adaptive design: Amortizing sequential Bayesian experimental design. In *International Conference on Machine Learning*, 2021. arXiv:2103.02438.
- S. Ghosal and A. van der Vaart. *Fundamentals of Nonparametric Bayesian Inference*. Cambridge Series in Statistical and Probabilistic Mathematics. Cambridge University Press, 2017.
- J. Gottweis, W.-H. Weng, A. Daryin, T. Tu, P. Sirkovic, A. Myaskovsky, G. Glowatyj, F. Weissenberger, A. Orlandi, D. Popovici, et al. Accelerating scientific discovery with Co-Scientist. *Nature*, 2026. doi: 10.1038/s41586-026-10644-y. arXiv:2502.18864.
- J. Jaber and O. Jaber. AutoKernel: Autonomous GPU kernel optimization via iterative agent-driven search. arXiv preprint arXiv:2603.21331, 2026.
- J. Jumper, R. Evans, A. Pritzel, T. Green, M. Figurnov, O. Ronneberger, K. Tunyasuvunakool, R. Bates, A. Židek, A. Potapenko, et al. Highly accurate protein structure prediction with AlphaFold. *Nature*, 596:583–589, 2021.
- L. P. Kaelbling, M. L. Littman, and A. R. Cassandra. Planning and acting in partially observable stochastic domains. *Artificial Intelligence*, 101(1-2):99–134, 1998.
- J. Liu et al. The last human-written paper: Agent-Native research artifacts. arXiv preprint arXiv:2604.24658, 2026. arXiv:2604.24658.
- C. Lu, C. Lu, R. T. Lange, J. Foerster, J. Clune, and D. Ha. The AI Scientist: Towards fully automated open-ended scientific discovery. arXiv preprint arXiv:2408.06292, 2024.
- C. Lu, C. Lu, R. T. Lange, Y. Yamada, S. Hu, J. Foerster, D. Ha, and J. Clune. Towards end-to-end automation of AI research. *Nature*, 651:914–919, 2026. doi: 10.1038/s41586-026-10265-5.
- B. S. Manning, K. Zhu, and J. J. Horton. Automated social science: Language models as scientist and subjects. NBER Working Paper, (32381), 2024. arXiv:2404.11794.
- A. Merchant, S. Batzner, S. S. Schoenholz, M. Aykol, G. Cheon, and E. D. Cubuk. Scaling deep learning for materials discovery. *Nature*, 624:80–85, 2023.
- O. O’Donoghue, G. Puthumanaillam, J. Won, P. Moura, M. Oettig, J. M. de Kruif, M. Gini, M. Heinonen, and P. Sloot. BioPlanner: Automatic evaluation of LLMs on protocol planning in biology. arXiv preprint arXiv:2310.10632, 2023.
- J. S. Park, J. C. O’Brien, C. J. Cai, M. R. Morris, P. Liang, and M. S. Bernstein. Generative agents: Interactive simulacra of human behavior. In *Proceedings of the ACM Symposium on User Interface Software and Technology*, 2023. arXiv:2304.03442.
- T. Rainforth, A. Foster, D. R. Ivanova, and F. B. Smith. Modern Bayesian experimental design. *Statistical Science*, 2024. arXiv:2302.14545.
- E. Real, C. Liang, D. So, and Q. Le. AutoML-Zero: Evolving machine learning algorithms from scratch. In *International Conference on Machine Learning*, 2020. arXiv:2003.03384.

- B. Romera-Paredes, M. Barekataan, A. Novikov, M. Balog, M. P. Kumar, E. Dupont, F. J. R. Ruiz, J. Ellenberg, P. Wang, O. Fawzi, et al. Mathematical discoveries from program search with large language models. *Nature*, 625:468–475, 2024.
- C. C. Sartori and C. Blum. Algorithm discovery with large language models: Evolutionary search meets transformer. *arXiv preprint arXiv:2411.00895*, 2024.
- S. Schmidgall, Y. Su, Z. Wang, X. Sun, J. Wu, X. Yu, J. Liu, and E. Barsoum. Agent Laboratory: Using LLM agents as research assistants. *arXiv preprint arXiv:2501.04227*, 2025.
- C. Si, D. Yang, and T. Hashimoto. Can LLMs generate novel research ideas? A large-scale human study with 100+ NLP researchers. *arXiv preprint arXiv:2409.04109*, 2024.
- A. Sparkes, W. Aubrey, E. Byrne, A. Clare, M. N. Khan, M. Liakata, M. Markham, J. Rowland, L. N. Soldatova, K. E. Whelan, M. Young, and R. D. King. Towards robot scientists for autonomous scientific discovery. *Automated Experimentation*, 2(1):1, 2010. doi: 10.1186/1759-4499-2-1.
- H. W. Sprueill, C. Edwards, K. Agarwal, M. Olarte, U. Sanyal, C. Johnston, H. Liu, H. Ji, and S. Bhatt. ChemReasoner: Heuristic search over a large language model’s knowledge space using quantum-chemical feedback. In *International Conference on Machine Learning*, 2024. *arXiv:2402.10980*.
- T. Taniguchi, S. Takagi, J. Otsuka, Y. Hayashi, and H. T. Hamada. Collective predictive coding as model of science: Formalizing scientific activities towards generative science. *Royal Society Open Science*, 12(6):241678, 2025. doi: 10.1098/rsos.241678. *arXiv:2409.00102*.
- S.-M. Udrescu and M. Tegmark. AI Feynman: A physics-inspired method for symbolic regression. *Science Advances*, 6(16):eaay2631, 2020.
- H. Xin, D. Ren, S. Song, Z. Shao, W. Zhao, H. Wang, W. Liu, L. Cheng, et al. DeepSeek-Prover-V1.5: Harnessing proof assistant feedback for reinforcement learning and Monte-Carlo tree search. *arXiv preprint arXiv:2408.08152*, 2024. *arXiv:2408.08152*.
- B. Zhang, S. Feng, X. Yan, J. Yuan, Z. Yu, S. Huang, L. Bai, X. He, T. Peng, et al. NovelSeek: When agent becomes the scientist – building closed-loop system from hypothesis to verification. *arXiv preprint arXiv:2505.16938*, 2025. *arXiv:2505.16938*.

AI 참여 체크리스트

이 체크리스트는 CAISc 2026이 요구하는 대로 이 연구의 각 단계에서 AI 시스템의 역할을 문서화한다.

- 가설 개발. 핵심 Servo 프레임워크 (S, G, E, V, M, π), H 매개변수, G 출력 스펙트럼(명제 가설 $\rightarrow$ 반증 가능한 구성), 세 가지 미해결 문제는 인간 저자가 구상했다. Claude Code(Anthropic)는 프레임워크 구성요소를 정교화하고, 각 구성요소의 논문 수준 구체화를 식별하며, 개념 간 연결을 제안했다.
- 문헌 검색 및 선택. 인간 저자가 포함 기준과 대상 시스템을 결정했다. Claude Code는 자율적으로 40개 이상의 전문 PDF를 검색, 열람하고, 논문들을 분류학으로 범주화하며, 원문 대비 주장 수준의 검증을 수행했다.
- 분석. Claude Code는 1차 자료를 읽어 13개 분석 시스템 각각의 S, G, E, V, M, π 구성요소를 추출했다. 인간 저자는 모든 추출을 검토하고, 오류를 수정(여러 실질적 수정이 필요했음)하며, 교차 시스템 패턴을 종합했다.
- 작성. Claude Code가 이 원고의 대부분을 초안 작성했다. 인간 저자는 핵심 개념적 단락(특히 §7 및 §4의 핵심 정의)을 제공하고, 구조적 결정을 지시하며, 모든 초안을 검토했다.

전반적으로, 분업의 특성은 다음과 같다: 인간 저자는 지적 방향, 프레임워크 설계, 최종 판단을 제공했고; Claude Code는 문헌 검색, 분석 실행, 텍스트 생성을 담당했다.

책임 및 재현성 체크리스트

- 주장과 증거. 모든 경험적 주장은 인용된 1차 자료에 근거한다. 주요 주장은 원본 PDF의 직접 전문 열람으로 검증되었다.
- 한계. 이 논문은 기존 출판 시스템의 개념적 메타 분석이다. 독창적인 실험을 포함하지 않는다. Servo 프레임워크는 이 제출에서 보류 시스템에 대해 경험적으로 검증되지 않았으며; 기술적 적절성은 분석된 13개 시스템 전반의 일관성에 달려있다.
- 재현성. 시스템 선택과 구성요소 추출 방법은 조작적 코딩 프로토콜로 문서화되며, 셀별 출처 인용이 달린 기계가독 코딩 시트, 서로 다른 벤더의 모델 고정 LLM 평가자 3개에 의한 14개 시스템 다중벤더 블라인드 코딩과 Fleiss' κ , 반례 탐색, 표 재생성·검증 스크립트를 보충 자료로 공개한다. Servo은 구성요소 정의에 따라 어떤 AI 과학자 시스템에도 적용될 수 있으며, 분석된 모든 논문은 공개적으로 접근 가능하다. 독점 데이터나 비공개 모델은 사용되지 않았다.
- 실험 세부사항. 문헌 검토 방법론은 Muka et al. (2020) 24단계 체계적 검토 지침을 따른다. 시스템 선택 기준: 가설-실험-검증 루프의 최소 하나의 구성요소를 자동화한다.
- 데이터 및 코드 가용성. 코딩 프로토콜(coding_protocol.md), 출처 인용이 달린 코딩 시트(systems.csv), 신뢰도 보고서(reliability_report.md), 표 재생성·검증 스크립트를 analysis/ 디렉터리로 공개한다. 별도 데이터셋은 생성되지 않았다.
- 윤리적 및 사회적 영향. H 매개변수 분석은 현재 시스템에서 인간 감독의 필요성을 명시적으로 다룬다. §7의 미해결 문제 논의는 AI 과학자 광범위 배포 하의 조기 수렴 위험을 식별하며, 특히 M_s 미성숙 문제를 통해.